修　士　論　文

個別楽器音に基づく楽曲間類似度表現学習における知覚・知見・知識の導入

252406030　　今村 剛大

名古屋大学大学院情報学研究科

知能システム学専攻

２０２５年度

概要

音楽検索・推薦システムにおいて，特定の楽器音に着目した楽曲間類似度を表現する手法として，個別楽器音に基づく楽曲間類似度表現学習（Instrument-Wise Music Similarity Representation Learning; InMSRL）の研究が進められてきた．従来手法は「同一楽曲内のセグメントは異なる楽曲間のセグメントより類似している」という楽曲内類似度に基づいたトリプレット損失による自己教師あり学習を用いており，出力として各楽器音ごとの類似度特徴量を得る．各楽器音ごとの類似度特徴量はネットワーク単位または特徴量次元単位で出力される．

しかしながら，これらの従来手法には 3 つの課題が存在する．第一に，従来手法の学習基準である楽曲内類似度では，人間の知覚的な楽曲間類似度を十分に表現できないという点である．楽曲内類似度に基づいた学習によって楽曲間類似度や知覚的類似度を表現できる保証は存在しない．第二に，多数の楽器への対応の難しさである．従来手法では，ネットワーク単位または特徴量次元単位で楽器が割り当てられているため，多くの楽器を扱う場合に計算量とリソースが増大する．そのため，多数の楽器を学習させることが困難である．また，従来手法には学習に含まれていない楽器に頑健に動作するための機構が存在しない．音楽の多様性ゆえに全ての楽器を学習で網羅することは難しく，未知楽器に対しても頑健に動作する InMSRL モデルが求められる．

本論文では，人間の知覚，知見，知識を活用した 3 つの提案手法により，これらの課題に取り組む．第一の提案手法では，人間の知見に基づいて設計された信号処理に基づく楽曲間類似度表現手法（Signal-Processing-based Music Similarity Representation;

SP-MSR）を自己教師あり学習の類似度基準として導入し，知覚的類似度表現性能を改善する．第二の提案手法である PAFT（Perception-Aware Fine-Tuning）では，人手で付与された少量の知覚的類似度ラベルを用いた Fine-Tuning により，人間が実際に感じる楽曲間類似度をモデルに学習させる．第三の提案手法では，テキスト表現による楽器指定手法を導入し，テキストと楽曲間の大規模対照学習で得られるテキスト特徴量を用いて類似度特徴量抽出器を条件付けることで，計算量の削減と未知楽器への対応を実現する．実験的評価により，SP-MSR で事前学習後に PAFT を適用する手法が最高性能を達成すること，およびテキスト表現による楽器指定手法については，従来手法に対して性能では劣るものの，より多くの楽器の学習と未知楽器への対応がある程度可能であることを示した．

Abstract

Instrument-Wise Music Similarity Representation Learning (InMSRL) has been studied as a method to represent inter-song similarity with a focus on specific instrument sounds in music retrieval and recommendation systems. Conventional methods employ self-supervised learning using triplet loss based on intra-song similarity, which assumes that "segments within the same song are more similar than segments from different songs," to obtain similarity features for each instrument sound. The similarity features for each instrument sound are output on a network-wise or feature-dimension-wise basis.

However, these conventional methods have three challenges. First, the intra-song similarity used as the learning criterion in conventional methods cannot sufficiently represent human perceptual inter-song similarity. There is no guarantee that learning based on intra-song similarity can acquire inter-song similarity or perceptual similarity. Second, it is difficult to handle a large number of instruments. In conventional methods, instruments are assigned on a network-wise or feature-dimension-wise basis, leading to increased computational cost and resources when handling many instruments. Therefore, it is difficult to train models for a large number of instruments. Furthermore, conventional methods lack mechanisms to operate robustly for instruments not included during training. Due to the diversity of music, it is difficult to cover all instruments in training, and InMSRL models that can operate robustly for

unknown instruments are required.

This thesis addresses these challenges through three proposed methods that leverage human perception, knowledge, and insights. The first proposed method introduces Signal-Processing-based Music Similarity Representation (SP-MSR), designed based on human musical knowledge, as a similarity criterion for self-supervised learning to improve perceptual similarity representation performance. The second proposed method, Perception-Aware Fine-Tuning (PAFT), trains models to learn inter-song similarity as actually perceived by humans through fine-tuning with a small amount of manually annotated perceptual similarity labels. The third proposed method introduces an instrument specification approach using text representations, conditioning the similarity feature extractor with text features obtained from large-scale contrastive learning between text and music, thereby reducing computational cost and enabling handling of unknown instruments. Experimental evaluation demonstrates that the method applying PAFT after pre-training with SP-MSR achieves the highest performance, and that the text-based instrument specification approach, while inferior in performance to conventional methods, enables learning a larger number of instruments and handling unknown instruments to some extent.

目 次

概要 **i**

Abstract **iii**

第 1 章　序論 **3**

1.1　はじめに 3

1.2　本研究の目的 7

1.3　本論文の構成 8

第 2 章　従来手法および関連研究 **9**

2.1　はじめに 9

2.2　個別楽器音に着目した楽曲間類似度表現学習の従来手法 9

2.2.1　*Clean* 10

2.2.2　*Cascade* 12

2.2.3　*Direct* 13

2.3　従来手法の楽曲間類似度表現性能および知覚的類似度表現性能について 16

2.4　U-Net を用いた音源分離手法 17

2.5　知覚的類似度ラベルを用いた学習手法 19

2.6　音声-テキスト間の対照学習に基づく音源分離および特徴量抽出のためのテキスト条件付け 19

2.6.1 テキストと音響間の対照学習 20
2.6.2 FiLM によるネットワークの条件付け 21
2.6.3 FiLM を用いたテキスト表現による音源分離 21
2.6.4 FiLM によるテキスト特徴量を用いた条件付き特徴量抽出 22
2.7 本章のまとめ 23

第 3 章 人間の知覚および知見を活用した学習戦略 25
3.1 はじめに 25
3.2 提案する学習戦略 25
3.2.1 事前学習で導入する信号処理による楽曲間類似度表現手法 . . . 26
Global Temporal Averaging (GlobalTA) 27
Localized Timbral Similarity (LocalTS) 27
Fluctuation Patterns (FPs) 28
複数の SP-MSR 手法の統合 29
3.2.2 事前学習 29
3.2.3 Perception-Aware Fine-Tuning (PAFT) 31
3.3 実験的評価 32
3.3.1 データセット 32
3.3.2 実験設定 33
3.3.3 ベースラインモデル 35
3.3.4 評価指標 35
3.3.5 評価結果 36
SP-MSR のみでの性能評価 36
PAFT の性能評価 36
SP-MSR の学習への応用による性能評価 37
SP-MSR のみの性能と学習へ応用した場合の性能の比較 38

3.4 本章のまとめ 39

第 4 章 テキスト表現による楽器指定 45

4.1 はじめに 45
4.2 ネットワーク構造 45
4.2.1 全体構造 45
4.2.2 テキスト特徴量抽出器 46
4.2.3 FiLM による条件付け 47
4.2.4 類似度特徴量抽出器 47
4.2.5 楽器音再構成器 48
4.3 学習手法 49
4.3.1 事前学習：分離音の再構成損失 49
4.3.2 分離損失とトリプレット損失による同時学習 50
4.4 実験的評価 51
4.4.1 データセット 51
学習対象楽器の選択 52
4.4.2 実験設定 53
4.4.3 ベースライン 53
4.4.4 評価指標 54
通常テスト楽曲における楽曲 ID 推定スコア（MES-Normal） . 54
擬似テスト楽曲における楽曲 ID 推定スコア（MES-Pseudo） . . 54
擬似テスト楽曲に対する評価値の可視化 56
4.4.5 評価結果 56
上位楽器区分に属する楽器に対する評価結果 56
下位楽器区分に対する評価結果 59
4.4.6 議論 60

擬似テスト楽曲に対する評価値の可視化 60
Slakh-Super で学習されたモデルを Slakh-Sub で評価 61
Slakh-Sub の楽器の類似度特徴量空間の可視化 62
Slakh-Sub の全楽器に対する類似度特徴量の可視化結果 62
4.5 本章のまとめ 63

第 5 章 結論 **67**
5.1 本論文のまとめ 67
5.2 今後の課題 69

謝辞 **71**

参考文献 **73**

研究業績 **83**

第1章　序論

1.1　はじめに

音楽市場は年々拡大し続けているが，近年のインターネットおよびスマートフォンの普及により，CD などの物理的形式からデジタル（特にストリーミング）形式へと消費の中心が移行してきたことが大きく影響していると考えられる．IFPI によれば，2024 年の世界の録音音楽市場（recorded music）の総売上は 296 億アメリカドルで，前年比 4.8%増となり，10 年連続の上昇である [1]．また，ストリーミング売上は初めて 200 億ドルを超える 204 億アメリカドルに達し，市場全体の 69.0%を占めている [1]．加えて，有料サブスクリプションのアカウントユーザ数は世界で 7 億 5200 万人に増加しており，市場拡大の主因がサブスクリプション型ストリーミングであることが示唆される [1]．中でも世界的なシェアを集めているサブスクリプションサービス Spotify では，2025 年第 3 四半期時点で月間アクティブユーザー数が 7 億 1300 万人，Premium 加入者数が 2 億 8100 万人に到達している [2]．さらに，2024 年末時点で音楽ストリーミングサービス上で把握されるオーディオ ISRC は約 2 億 200 万（202M）に達し，配信プラットフォームには 1 日平均約 9.9 万曲が追加されている [3]．音楽市場は音楽ストリーミングサービスの更なる成長に伴い，今後も拡大を続けるであろう．このサブスクリプションサービスのユーザは膨大な楽曲の中から好みのものを見つけていくが，全ての楽曲を聴くことは現実的ではない．そこで，ユーザにより多くの楽曲を聴いてもらい，より効率よく好みの楽曲を発見してもらうために有効なのは，楽曲推薦システムなどの音楽情報検索（Music Information Retrieval; MIR）技術である．

MIR技術の中で最も一般的に用いられているものは，テキストによるメタデータ検索である．この手法では楽曲固有データである曲名，アーティスト名，ジャンルなどに対し，テキスト検索でキーと一致するものをフィルタリングする手法であるが，曲名やアーティスト名などの客観的情報は表現力に限界があるという問題点がある．また別のアプローチとして，ユーザのリスニング履歴を活用した協調フィルタリングという手法 [4] がある．この手法では異なるユーザが複数のコンテンツに対して似たような評価をした場合，他のコンテンツに対しても同様の評価を示すという仮定に基づいて，ユーザ間の類似度を計算し，近傍ユーザの評価を元に未評価のコンテンツを推薦する [5]．ただ問題点として，まだ評価や行動が蓄積していないユーザやコンテンツに対して適切な推薦が行われないというコールドスタート問題 [4] や，人気の楽曲が推薦されやすいという点 [4] が挙げられる．この問題を回避する一つの方法として，楽曲から内容特徴量（コンテンツ特徴量）を抽出し，それを推薦や検索に利用するアプローチが挙げられる．

音楽特徴量抽出モデルとしては，古典的手法 [6, 7, 8] がこれまで検討されてきた．これらの手法では，メル周波数ケプストラム係数（mel-frequency cepstral coefficients; MFCC）[9] や 変調スペクトル（fluctuation patterns; FPs） [10, 11] などの特徴量を，k-means クラスタリング [12] やガウス混合モデル（Gaussian mixture modeling; GMM）[13, 14] によりモデル化する方法が用いられてきた．近年では，深層学習に基づく手法が高精度な特徴抽出を可能にすることから注目を集めており，畳み込みニューラルネットワーク（convolutional neural network; CNN）[15, 16, 17, 18, 19, 20] を利用する研究が多数報告され，高い性能を示している．

特に, 教師なし・自己教師あり・半教師あり学習に基づく楽曲間類似度表現学習（Music Similarity Representation Learning; MSRL）は，未知データへの適応性が高く，音楽タグ付け，ジャンル分類，キー推定など多様な下流タスクに応用できる点から，近年広く研究されている [21, 22, 23]．アーティストラベル [24] や音楽タグ [25] を用いた ト

リプレット損失 [26, 27] による学習は，音楽分類タスクにおける性能向上やゼロショット性能の向上に寄与することが示されている．さらに，「同一楽曲内のセグメント同士は，異なる楽曲間のセグメント同士より類似している」という類似度仮定（本論文では楽曲内類似度と呼ぶ）に基づく対照学習 [28, 23] や，さらにデータ拡張を導入した手法 [29, 30] は，ラベルを必要としないにもかかわらず，複数のタスクで強力な性能を示している [31]．加えて，HuBERT [32] に代表される masked language modeling [33] を音楽に適用した手法は，k-means による教師ラベル [21]，EnCodec [34]，あるいは data2vec [35] を音楽に適用した手法 [22] を利用することで，多くの下流タスクで高い効果を達成している．音楽生成モデル [36] の中間層出力を利用する方法 [37] や，テキストと音楽間の対照学習 [38] も，音楽表現を獲得する手法として確立されている．

しかし，MSRL は一般に各楽曲に対して単一の汎用的な特徴表現を生成するため，多くの下流タスクには十分であるものの，個々のユーザの多様な嗜好に応じるためには複数の補完的記述子が求められる場合がある．この課題に対し，楽曲中の個別楽器音に基づく MSRL（Instrument-Wise MSRL; InMSRL）[39, 40] が提案されている．InMSRL では楽曲内の各楽器に対応する特徴ベクトルを生成し，楽曲の多次元的な表現を可能にする．これにより，ピアノのみ・ドラムのみ・ギターのみといった楽器別の埋め込み表現を用いて，推薦や検索結果を楽器単位で制御できる．例えば，ユーザが推薦結果に満足できなかった場合に，ユーザは「ピアノの音が類似した曲を推薦してほしい」というような指示が可能となり，明示的に類似してほしい視点を指定して再検索・再推薦が可能となる．これにより，各々が納得できる推薦結果にたどり着くことができる検索・推薦システムの構築に近づくことができる．

従来の InMSRL モデルは，MSRL において有効性が示されている楽曲内類似度仮定 [28, 23] に基づいて学習されており，特に個別楽器音のラベルがほとんど存在しない状況において有利である．楽曲から各楽器ごとの類似度表現を得るため，これまでに *Clean* [39]，*Cascade* [39, 41]，*Direct* [40, 41] の 3 手法が提案されている．*Clean* は

クリーンな個別楽器ステムを入力とすることで高い性能を示すが，推論時にもステムが必要となるため一般的な環境では利用が困難である．この制約を解決するため，楽曲そのものを入力として個別楽器の類似度表現を得る *Cascade* および *Direct* の研究が進められてきた．*Cascade* は楽曲音源分離（music source separation; MSS）[42] と類似度特徴量抽出を逐次的に行う手法であり，この構造により個別楽器の特徴が明確に分離されることが期待される．一方，*Direct* は単一の特徴抽出器により，楽器ごとに独立したサブスペースからなる分離特徴表現を直接学習する手法であり，画像や音楽における複数の異なるラベルを推測する手法 [43, 44] に類似した枠組みを採用する．この構造により，*Cascade* に比べて計算コストを低減でき，また MSS に起因するアーティファクトの影響も避けられる．

しかし，従来の InMSRL 手法には以下の 2 つの課題が存在する．第一の課題は，楽曲間類似度および知覚的類似度の表現不足である．*Clean*，*Cascade*，*Direct* は楽曲内類似度に基づく学習により，同一楽曲内におけるセグメント間の音楽類似度表現を獲得することには成功しているものの，この学習アプローチが異なる楽曲間の類似度を捉えられる，あるいは人間の知覚的類似度に対応するという保証はない．実際，先行研究 [45] では，楽曲内類似度に基づくモデルから得られる同一楽曲内の類似度表現は人間の知覚と強い相関を示す一方で，異なる楽曲間の類似度表現は人間の知覚との相関が不十分であることが報告されている．

第二の課題は，多数の楽器に対応することの難しさである．従来手法では，*drums*，*bass*，*piano*，*guitar* の 4 種類の楽器のみを対象としており，より多様な楽器に対応可能な検索・推薦システムが求められている．特に，*piano* のような大きなカテゴリにとどまらず，*classic piano*，*electronic piano*，*upright piano* といった細粒度の楽器指定が必要となる場合もあり，多様な楽器条件に柔軟に適応可能な InMSRL モデルの構築が重要である．ここで，従来手法において，より多くの楽器を扱う場合を考える．従来手法では，モデル単位（*Clean*，*Cascade*）あるいは特徴量次元単位（*Direct*）で楽

器が割り当てられている．そのため，類似度表現学習の対象となる楽器数が増加すると，学習に必要な計算量および計算資源が大幅に増加してしまう．このことから，従来手法の枠組みでは，多数の楽器を同時に扱うことは困難であることがわかる．さらに，音楽の多様性を考慮すると，すべての楽器を事前に学習データに含めることは現実的ではない．したがって，学習時に観測されない未知の楽器に対しても，類似度特徴量を抽出可能であることが望ましい．しかしながら，従来手法には，学習外の楽器に対して頑健に動作するための機構が存在しない．そのため，新規楽器や学習データに含まれていない楽器への対応は困難である．

1.2 本研究の目的

本研究では, 従来手法に残存する 2 つの課題に対して, 音楽に対する人間の実際の知覚情報, 人間が感覚的に持つ音楽的知見, および人間が言葉で説明可能な音楽的知識の 3 つを活用して改善を目指す．第一に, 信号処理に基づく楽曲間類似度表現（Signal-Processing-based Music Similarity Representation; SP-MSR）を従来手法の自己教師あり学習の類似度基準として導入する．SP-MSR は，Global Temporal Averaging（GlobalTA），Localized Timbral Similarity（LocalTS），Fluctuation Patterns（FPs）といった，人間が感覚的に持つ音楽的知見に基づいて設計された手法であり，これらを学習に組み込むことで，楽曲内類似度だけでは表現できない複雑な類似度特徴をモデルに学習させることができる．

第二に，人手で付与された少量の知覚的類似度ラベルを用いた Fine-Tuning 手法（Perception-Aware Fine-Tuning; PAFT）を提案する．PAFT では，人間が実際に感じる楽曲間類似度を直接モデルに学習させることで，楽曲内類似度では表現できない知覚的類似度を模倣する．

第三に，テキスト表現による楽器指定手法を提案する．この手法では，楽曲とその楽

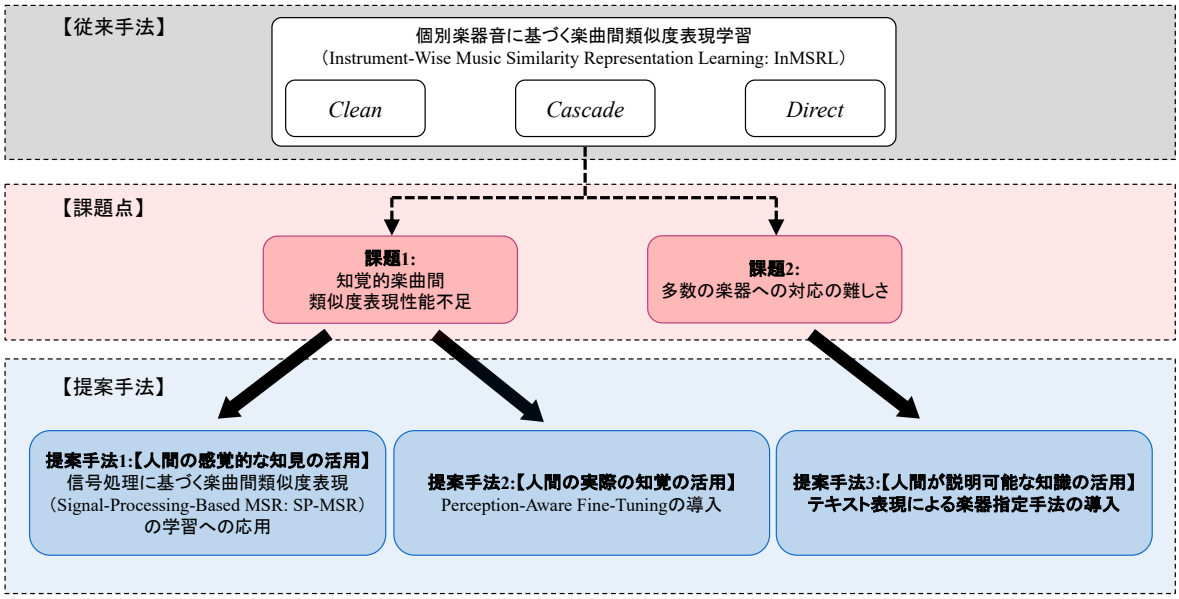


図 1.1: 本論文の概要.

曲を人間が知識に基づいて説明したテキストを用いて，楽曲とテキスト間の大規模対照学習を行うことで得られるテキスト特徴量を用いて，類似度特徴量抽出器を条件付けする．テキスト単位での楽器割り当てにより，楽器数増加によるリソース増加を抑制でき，人間の知識に基づいて学習されたテキスト特徴量抽出器の頑健性により，学習されていない楽器にも対応可能となる．

1.3　本論文の構成

本論文の構成は以下の通りである．第 2 章では，InMSRL の従来手法と関連研究について述べる．第 3 章では，提案手法である SP-MSR に基づく学習と PAFT について，およびそれらの実験的評価について述べる．第 4 章では，提案手法であるテキスト表現による楽器指定手法について，およびそれらの実験的評価について述べる．第 5 章では，本研究の結論と今後の展望について述べる．

第2章　従来手法および関連研究

2.1　はじめに

本章では，InMSRL の従来手法および関連研究について述べる．2.2 節では，InMSRL の従来手法である *Clean* 手法，*Cascade* 手法，*Direct* 手法について述べる．2.3 節では，従来手法の楽曲間類似度表現性能および知覚的類似度表現性能について述べる．2.4 節では，音源分離で広く用いられている U-Net について述べる．2.5 節では，知覚的類似度ラベルを用いた学習手法について述べる．2.6 節では，テキスト表現による特徴量抽出手法について述べる．

2.2　個別楽器音に着目した楽曲間類似度表現学習の従来手法

個別楽器音に基づく楽曲間類似度表現学習（Instrument-Wise Music Similarity Representation Learning: InMSRL）は，楽曲内の各楽器に対応する特徴ベクトルを生成することで，楽曲の多次元的な表現を可能にする手法である．従来の MSRL が楽曲全体に対して単一の特徴表現を生成するのに対し，InMSRL はピアノ，ドラム，ギター，ベースなどの楽器ごとに独立した特徴表現を学習する．これにより，ユーザは「ピアノの音が類似した曲を推薦してほしい」といった楽器単位での検索・推薦が可能となる．

InMSRL の従来手法は，図 2.1 に示すように，混合楽器音から各楽器ごとの類似度表現を得る方法により，*Clean*，*Cascade*，*Direct* の 3 つに分類される．これらの手法は

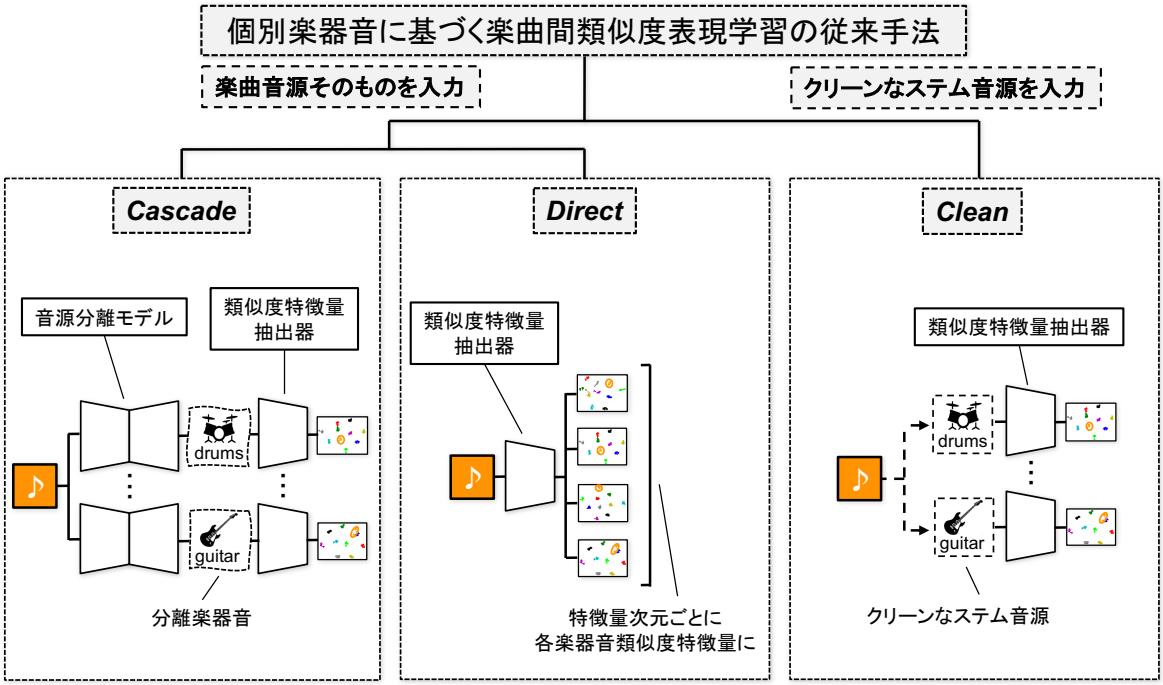


図 2.1: 個別楽器音に基づく楽曲間類似度表現学習の従来手法の概要.

いずれも，MSRL において有効性が示されている楽曲内類似度仮定に基づいて学習される．「同一楽曲内のセグメント同士は，異なる楽曲間のセグメント同士より類似している」という楽曲内類似度仮定に基づき，トリプレット損失 [46, 27] による自己教師あり学習が適用される．以下では，各手法の概要，利点，問題点について述べる．

2.2.1 *Clean*

Clean 手法は，InMSRL において最初に提案された手法であり，ステム音源（分離済みの個別楽器音源）自体を類似度特徴量抽出器に入力する [39]．具体的には，各楽器のステム音源に対して独立した類似度特徴量抽出器を用意し，それぞれの抽出器を楽曲内類似度仮定に基づくトリプレット損失で学習する．

トリプレット損失は，アンカーサンプル $\boldsymbol{x}_a$，ポジティブサンプル $\boldsymbol{x}_p$，ネガティブサ

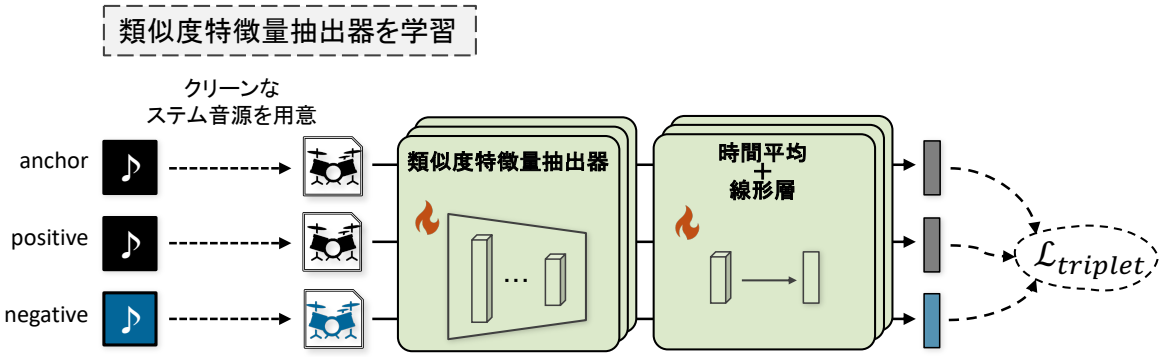


図 2.2: *Clean* 手法の概要．$\mathcal{L}_{triplet}$ はトリプレット損失を表す．

ンプル $\boldsymbol{x}_n$ の 3 つ組を用いて，以下のように定義される：

$$\mathcal{L}_{\text{triplet}} = \max(0, d(\boldsymbol{z}_a, \boldsymbol{z}_p) - d(\boldsymbol{z}_a, \boldsymbol{z}_n) + \alpha), \tag{2.1}$$

ここで，$\boldsymbol{z}_a = f(\boldsymbol{x}_a)$，$\boldsymbol{z}_p = f(\boldsymbol{x}_p)$，$\boldsymbol{z}_n = f(\boldsymbol{x}_n)$ は特徴量抽出器 f により抽出された特徴ベクトル，$d(\cdot, \cdot)$ は距離関数（例えばユークリッド距離），α はマージンパラメータである．この損失関数は，アンカーとポジティブサンプル間の距離がアンカーとネガティブサンプル間の距離よりもマージン α 以上小さくなるように学習を促す．

学習時には，同一楽曲内の異なる時刻から抽出したセグメントをアンカーとポジティブサンプルとし，異なる楽曲から抽出したセグメントをネガティブサンプルとする．これにより，各楽器の特徴量抽出器は，同一楽曲の同一楽器音を近い表現空間に，異なる楽曲の同一楽器音を遠い表現空間にマッピングするように学習される．

Clean 手法の利点は，高品質なステム音源を直接利用できるため，各楽器の特徴を明瞭に捉えることができ，客観的評価において高い性能を示す点である．特に，音源分離の誤差がないため，各楽器の音響特徴を正確に抽出できる．一方で，問題点として，推論時にもステム音源を入手する必要があるという実用上の制約がある．一般的な音楽ストリーミングサービスでは混合楽器音のみが提供されており，ステム音源は通常入手困難である．そのため，*Clean* 手法は理想的な環境を想定した手法であり，実用的な音楽推薦・検索システムへの適用は困難である．

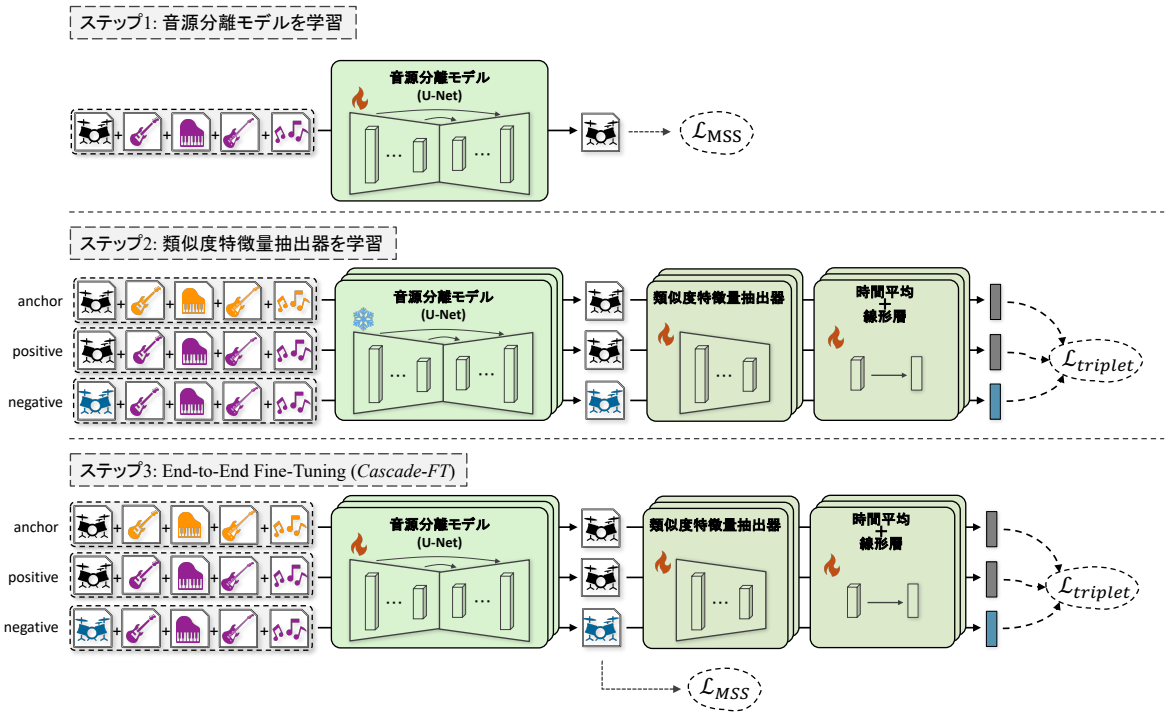


図 2.3: *Cascade* アプローチの概要．図は *Cascade-FT* の学習を表す．*Cascade* の学習はステップ 2 の学習のみで構成される．$\mathcal{L}_{triplet}$ はトリプレット損失を，$\mathcal{L}_{MSS}$ は音源分離損失を表す．

2.2.2 *Cascade*

Cascade（図 2.3）は，*Clean* 手法の実用性の問題を解決するために提案された手法であり，音源分離モデルによって分離された音源を類似度特徴量抽出器に入力する [39]．具体的には，まず混合楽器音を音源分離モデル（Spleeter [42]）に入力し，各楽器の分離音を得る．次に，得られた分離音を各楽器に対応する類似度特徴量抽出器に入力し，楽器ごとの類似度特徴量を抽出する．類似度特徴量抽出器の学習は，*Clean* 手法と同様に，楽曲内類似度仮定に基づくトリプレット損失で行われる．

Cascade-FT（図 2.3）は，*Cascade* 手法に新たに音源分離モデルの学習と，音源分離モデルと類似度特徴量抽出器の End-to-End な Fine-Tuning を導入している [41]．従

来の *Cascade* モデルは音源分離モデルのパラメータが固定されていたため，音源分離モデル由来の分離誤差が類似度特徴量抽出器の性能劣化につながっていると考えられる．*Cascade-FT* は音源分離モデルのパラメータを Fine-Tuning 時に学習可能にすることで，分離誤差を類似度特徴量抽出器に適応させる学習を導入した．さらに，学習時に擬似楽曲（2.2.3 節で後述）を導入している．擬似楽曲によって，分離誤差に含まれる非対象楽器音の影響を軽減することができ，分離誤差への頑健性を高めることにつながる．

Cascade 手法の利点は，推論時にステム音源を入手する必要がなく，混合楽器音のみから各楽器の類似度特徴量を抽出できる点である．これにより，一般的な音楽ストリーミングサービスにおいても適用可能な実用的な手法となる．一方で，問題点として，音源分離モデルによる分離誤差の影響を受けやすい点がある．*Cascade-FT* では分離誤差の影響を軽減する学習戦略が取られたが，音源分離モデル自体の性能向上につながっているわけではないため，いまだ分離誤差による性能劣化は引き起こされていると考えられる．

2.2.3 *Direct*

Direct（図 2.4）は，音源分離モデルを用いることなく，混合楽器音自体から各楽器音に基づく類似度特徴量を直接予測する手法である [40]．橋爪ら [40] は，単一の類似度特徴量抽出器を用いて，各楽器に対応した独立したサブスペースから構成される分離類似度特徴量を抽出する手法を提案している．例えば，640 次元の特徴ベクトルのうち，0 次元目から 127 次元目まではドラムに着目した楽曲間類似度を表現するために用いられる．学習プロセスは，まず事前学習から始まる．この学習では，単一の分離特徴抽出器は，*Clean* 手法により抽出された楽器ごとの類似度特徴を連結して形成される目標分離特徴を用いて学習される．次に，*Cascade* 手法と同様に，分離特徴量抽出器は式 (2.1) に示されるトリプレット損失を用いてさらに更新される．

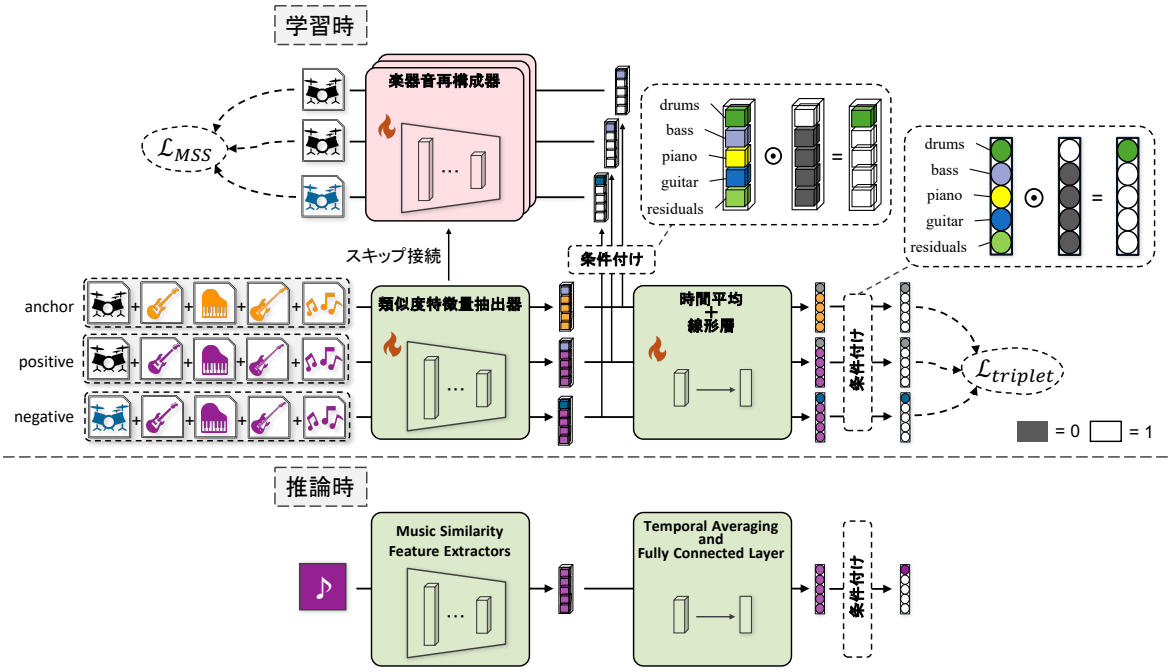


図 2.4: *Direct* アプローチの概要．学習時の図は *Direct-Reconst* を表す．*Direct* は楽器音再構成器を除いた部分のみで学習される．$\mathcal{L}_{triplet}$ はトリプレット損失を，$\mathcal{L}_{MSS}$ は音源分離損失を表す．

しかしながら，*Clean* 手法や *Cascade* 手法とは異なり，このような特徴量抽出器を学習することは容易ではない．分離楽曲類似度特徴量抽出器を適切に機能させるため，以下の 2 つのアプローチが用いられる：

- 分離楽曲類似度特徴量抽出器の出力の条件付け
- 擬似楽曲を入力として使用

条件付け処理（図 2.4 の条件付けを参照されたい）は，他の分離表現学習手法 [43, 44] に着想を得たマスク演算を行う．例えば，ベースの特徴に着目する場合，ベースの特徴に対応するサブスペースの次元成分のみを残し，他の次元成分を 0 にマスクする．特徴ベクトルを部分的にマスクすることで，各サブスペースは特定の楽器に依存した楽曲類似度特徴をモデル化できる．

擬似楽曲の使用は，モデルに対して楽曲から目標楽器の特徴のみを抽出するよう促すことを目的としている．図 2.5 に擬似楽曲の概要を示す．図 2.5 では，楽曲 α と楽曲 β はドラムにおいて類似しているが，他の楽器では非類似である．対照的に，楽曲 α と楽曲 γ はドラムでは非類似であるが，他の楽器では類似している．トリプレット損失に基づく学習において，楽曲 α をアンカー，楽曲 β をポジティブ，楽曲 γ をネガティブとして用いることで，モデルはドラムの特徴のみに着目できる．このトリプレット設定を基本トリプレットデータとして扱い，先行研究 [40] ではさらに追加のトリプレットデータを導入している．具体的には，追加のトリプレットデータは基本トリプレットデータのポジティブサンプルとネガティブサンプルを入れ替えることで構築され，追加のトリプレットデータを用いた学習中は，基本トリプレットデータとは異なる楽器が目標とされる．

さらに，*Direct-Reconst*（図 2.4）では，各楽器音特徴量分離性能および類似度表現性能をさらに高めるため，抽出された類似度特徴量からの各楽器音源の再構成を同時学習する学習手法が導入されている [41]．*Direct* において，楽曲中における楽器音特徴への着目は擬似楽曲に依存しているが，楽器音特徴量分離性能は十分ではない．そこで，*Direct-Reconst* は，出力楽器音類似度特徴量から楽器音源の再構成を同時学習することで，類似度特徴量抽出器に各楽器音特徴の抽出をさらに促す．

Direct 手法の利点は，音源分離モデルを持たないため，分離誤差の影響がない点である．また，*Cascade* 手法に比べて計算コストを低減でき，音源分離に起因するアーティファクトの影響も避けられる．一方で，問題点として，客観的評価において *Cascade* 手法に性能で劣る点がある．これは，混合音内では異なる楽器の信号が重なり合っているため，単一の楽器の特性を分離することが難しいためである．その結果，*Direct* 手法に基づく InMSRL の性能は不十分となる傾向がある．

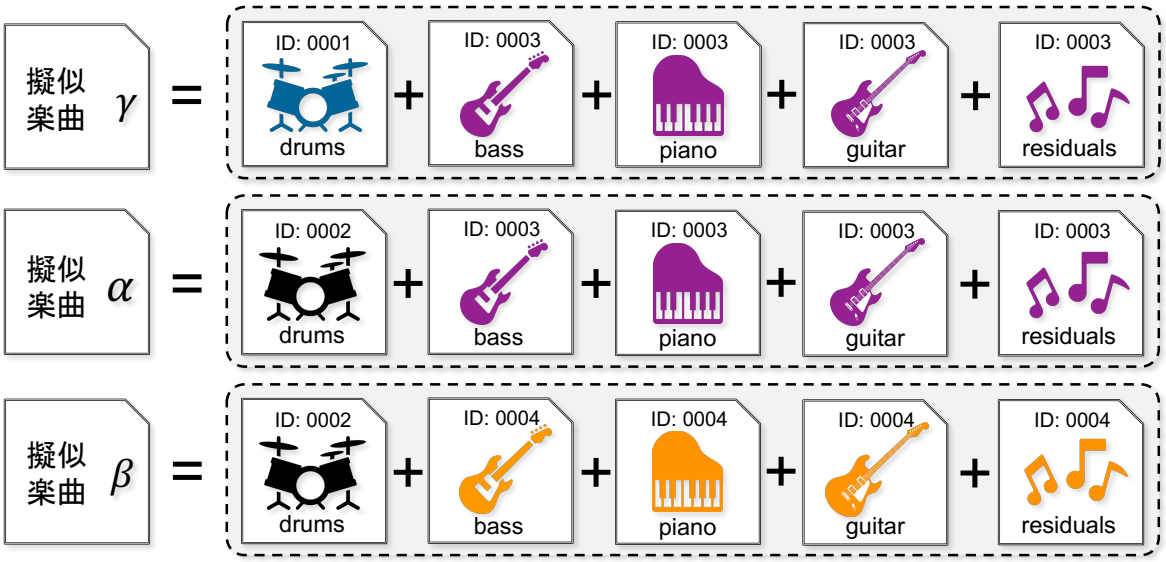


図 2.5: 擬似楽曲の概要図．楽曲 α と楽曲 β はドラムでは類似しているが他の楽器では非類似であり，楽曲 α と楽曲 γ はドラムでは非類似であるが他の楽器では類似している．

2.3　従来手法の楽曲間類似度表現性能および知覚的類似度表現性能について

橋爪ら [45] は，人間の嗜好ラベルの大規模データセットを収集し，楽曲中の個別楽器ステム間の類似性に関する人間の知覚を分析した．具体的には，586 人の被験者を対象に ABX テストを実施し，各被験者に対して 3 つの楽曲セグメント（X，A，B）が与えられ，「X は A と B のどちらに類似しているか」という質問に回答させた．ABX データセットの構築にあたっては，比較のための以下の 2 つの条件が定義された：

- **All-Diff 条件**: X，A，B はすべて異なる楽曲から抽出される
- **One-Shared 条件**: A または B のいずれかが X と同一楽曲から抽出される

ABX データセットは，drums，bass，piano，guitar，residuals，mix の 6 種類のト

ラックを含み，各トラックに対して 240 ペアずつ，合計 480 ペアの ABX データが含まれる．ここで，residuals は楽曲中の drums，bass，piano，guitar 以外の全ての音を指し，mix は楽曲の完全な混合音を表す．また，実験では各被験者に対して目的楽器の clean ステム音源が提示される．各 ABX データペアは少なくとも 3 人の被験者によって評価され，合計 26,898 件の有効な回答が得られた．

さらに，橋爪ら [45] は，楽曲内類似度仮定に基づいて学習された従来の InMSRL モデルの知覚的類似度表現性能に関する実験的評価を実施した．評価結果から，One-Shared 条件においては，人間の知覚的類似度と従来モデルによる類似度の間に強い相関が観測された．One-Shared 条件では A または B のいずれかが楽曲内類似度仮定を満たすため，楽曲内類似度仮定が人間の知覚的類似度とある程度一致しており，従来の InMSRL モデルが同一楽曲内のセグメント間の類似度を表現できることが示唆される．しかし，All-Diff 条件においては，人間の知覚的類似度と従来モデルによる類似度の間に弱い相関しか観測されなかった．これは，従来の InMSRL モデルが異なる楽曲間のセグメント間の類似度を表現するには不十分であることを示している．楽曲内類似度仮定に基づく学習が楽曲内類似度仮定に適合した類似度の捕捉に成功していることから，このアプローチは楽曲内類似度仮定に適合しない異なる楽曲間の類似度を学習するには効果が限定的である可能性がある．

これらの知見から，従来手法の主な課題は，客観的指標の向上だけでなく，人間の知覚的類似度をより適切に表現するための学習手法の開発が必要であることが明らかになった．

2.4 U-Net を用いた音源分離手法

U-Net [47] は医療画像のセマンティックセグメンテーションで用いられたモデルである．U-Net はオートエンコーダと類似した構造であり，入力をエンコーダとデコー

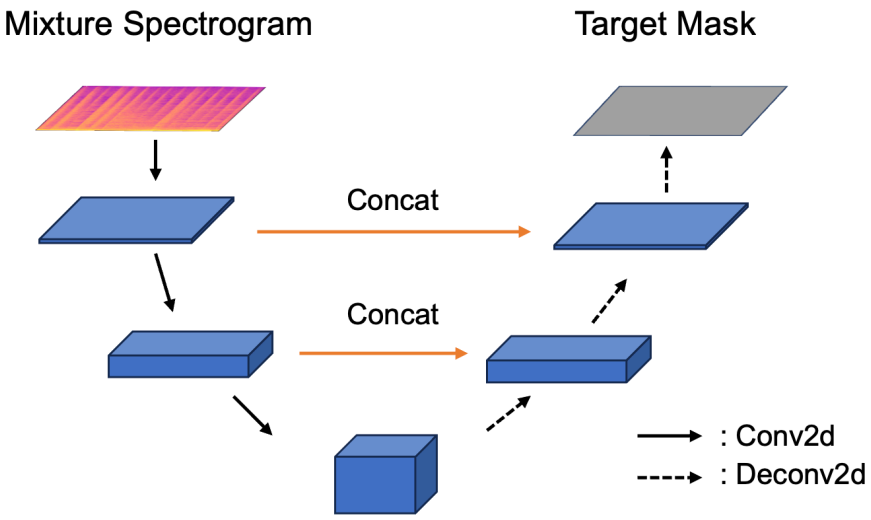


図 2.6: 音源分離で利用された U-Net の概要図．この図では 3 層のエンコーダ・デコーダだが，実際は 6 層ある．

ダで処理して，入力と同じサイズのデータが出力される．しかしオートエンコーダと異なる点として，エンコーダ・デコーダの各層の間にスキップ接続が存在する．スキップ接続は，エンコーダの出力を次のエンコーダに渡すだけなく，同じ階層のデコーダにも渡す．このスキップ接続によって，デコーダはエンコーダから圧縮された重要な情報だけでなくより精緻な情報を受け取ることができるため，出力画像を高解像度化することができる．

U-Net は楽曲音源分離にも活用されている [48][42]．音源分離において用いられた U-Net モデルの概要図が図 2.6 である．音源分離における U-Net の入力は混合音スペクトログラムで出力は抽出したい分離音のマスクである。このマスクと入力混合音スペクトログラムとをかけ合わせることで、目的の分離音スペクトログラムを得ることができる。

2.5 知覚的類似度ラベルを用いた学習手法

様々な研究分野において，学習された埋め込み空間を人間の主観性に適合させるために，人間の好みラベルを学習に組み込む試みがなされている．音声品質予測の分野では，人間が付与した平均オピニオン評点（Mean Opinion Score）を用いた対照学習が導入されている [49, 50]．話者埋め込みの分野では，収集された知覚的類似度評価に基づいて類似度行列を構築し，その行列の次元削減表現をモデルが予測するように学習する手法が提案されている [51]．さらに，音楽情報検索の分野では，アーティスト類似度表現の領域において，アーティスト間の類似性に関する人間の知覚的判断に基づいて類似・非類似のトリプレットを構築し，それを学習に適用する手法が提案されている [52]．

人間の好みラベルを学習に適用することは, 人間の知覚的類似度を反映したInMSRLを実現するための効果的なアプローチであると期待される．しかしながら, 従来のInMSRL手法では，人間の知覚的類似度ラベルを直接学習に組み込む試みはほとんど行われていない．これは，楽器ごとの知覚的類似度ラベルを大規模に収集することが困難であり，また楽曲内類似度仮定に基づく自己教師あり学習が主流であったためである．そのため，少量の知覚的類似度ラベルを効果的に活用する学習手法の開発が重要な課題となっている．

2.6 音声-テキスト間の対照学習に基づく音源分離および特徴量抽出のためのテキスト条件付け

近年，テキストと音響間の大規模対照学習に基づく手法が，音楽情報検索の分野で注目を集めている．これらの手法は，自然言語による楽曲記述と音響特徴を共通の埋め込み空間にマッピングすることで，テキストベースの楽曲検索やゼロショット分類などの

多様なタスクに対応できる汎用的な表現を獲得する．特に，MuLaN [38] や CLAP [53] といった手法は，テキスト特徴量抽出器として広く利用されている．

また，これらの手法で得られたテキスト特徴量を用いて，音響特徴抽出器を条件付ける手法も提案されている．以下では，テキストと音響間の対照学習手法と，それを用いた条件付き特徴抽出手法について述べる．

2.6.1　テキストと音響間の対照学習

近年，CLAP（Contrastive Language-Audio Pretraining）[53] や MuLan（Music Language Joint Embedding）[38] のような，テキストと音響間の大規模対照学習に基づく手法が提案されている．これらの手法では，音響エンコーダとテキストエンコーダがそれぞれ独立に特徴量を抽出し，対照学習により両者の特徴量が共通の埋め込み空間にマッピングされるよう学習される．

CLAP は一般的な音響を対象としており，約 633,500 の音響-テキストペアを含む LAION-Audio-630K データセットを用いて学習される．テキストから音響への検索，ゼロショット音響分類，教師あり音響分類など，多様なタスクにおいて高い性能を示している．一方，MuLan は音楽に特化した対照学習手法であり，4,400 万の楽曲録音（370,000 時間）と自由形式のテキストラベルのペアを用いて学習される．従来の音楽タグシステムのように予め定義された分類体系に制約されることなく，自然言語による多様な楽曲記述を扱える点が利点である．これにより，ゼロショット音楽タグ付け，楽曲領域における言語理解，クロスモーダル検索など，多様なタスクに応用できる．

さらに，MuLan を拡張した MuQ-MuLan（Music-Quantized MuLan）[54] が提案されている．MuQ-MuLan は，音楽音響表現を量子化することで，より効率的な埋め込み空間を構築し，検索タスクにおける性能向上を実現している．

2.6.2 FiLM によるネットワークの条件付け

MuLan や CLAP で得られたテキスト特徴量を活用するための条件付け手法として，Feature-wise Linear Modulation（FiLM） [55] が広く用いられている．FiLM は，条件情報に基づいて中間特徴マップに対してアフィン変換を適用する条件付け手法である．具体的には，テキスト特徴量からスケールパラメータ γ とシフトパラメータ β を生成し，音響特徴抽出器の中間層の特徴マップ $\boldsymbol{F}$ に対して以下の変換を適用する：

$$\mathrm{FiLM}(\boldsymbol{F}|\boldsymbol{c}) = \gamma(\boldsymbol{c}) \odot \boldsymbol{F} + \beta(\boldsymbol{c}), \tag{2.2}$$

ここで，$\boldsymbol{c}$ はテキスト特徴量，$\odot$ は要素ごとの積を表す．

FiLM の利点は，シンプルな機構でありながら，条件情報を効果的に特徴量抽出プロセスに組み込める点である．視覚的推論タスクにおいて高い性能を示しており，音響処理タスクへの応用も進められている．

2.6.3 FiLM を用いたテキスト表現による音源分離

テキスト表現を用いた条件付き音響処理の応用として，FiLM によるテキスト条件付けを用いた音源分離手法が提案されている．これらの手法では，事前学習されたテキスト・音響対照学習モデル（CLAP や MuLan など）から得られるテキスト特徴量を用いて，FiLM 機構により音源分離ネットワークの中間特徴マップを変調し，テキスト情報を反映させる．

Separate What You Describe [56] は，言語クエリに基づく音源分離手法を提案している．この手法では，テキストエンコーダで生成されたテキスト特徴量を用いて，U-Net 構造の音源分離ネットワークを FiLM により条件付ける．具体的には，テキスト特徴量からスケールパラメータ γ とシフトパラメータ β を生成し，U-Net の各デコーダ層の特徴マップに対してアフィン変換を適用する．FiLM を用いた条件付けにより，単一のモデルで多様な音源分離タスクに対応できる点が利点である．また，学習時に含

まれていないクラスに対してもゼロショット分離が可能であることが報告されている．CLAPSep [57] は，CLAP で事前学習されたテキスト特徴量抽出器を用いて，マルチモーダルクエリに基づく目的音抽出を行う手法である．この手法では,「ピアノの音」や「ドラムの音」といったテキスト記述により目的音を指定し，対応する音源を分離する．CLAPSep は，FiLM による条件付けを音源分離ネットワークに適用することで，テキスト情報を効果的に音源分離プロセスに組み込んでいる．テキストクエリに加えて，音響クエリや画像クエリも扱えるマルチモーダル性を持つ点が特徴である．Task-Aware Unified Source Separation [58] は，複数の音源分離タスクを単一のモデルで扱うための統一的な枠組みを提案している．この手法では，タスク記述をテキスト特徴量として埋め込み，FiLM を用いて分離ネットワークを条件付けることで，楽器分離・環境音分離・音声強調などを単一のモデルで実現している．FiLM による条件付けにより，音源分離のタスクは楽器分離，環境音分離，音声強調など多岐にわたるタスクを，従来のように各タスクごとに個別のモデルを用意することなく，統一的に扱うことができる．

これらの FiLM を用いたテキスト条件付き音源分離手法は，音源分離タスクにおいて高い柔軟性と性能を示しており，単一のモデルで多様な音源分離タスクに対応できる点が利点である．

2.6.4　FiLM によるテキスト特徴量を用いた条件付き特徴量抽出

音源分離の分野でテキスト条件付けが成功を収めているのと並行して，楽器レベルでの特徴抽出や検索タスクにおいても，FiLM と CLAP テキスト埋め込みを組み合わせた条件付け手法が提案されている．

Riou ら [59, 60] は，楽器ステム間の互換性を推定する Joint-Embedding Predictive Architecture（STEM-JEPA）において，CLAP から得られるテキスト埋め込みを用いた FiLM 条件付けを導入している．初期の研究 [59] では 4 つの固定楽器クラスに対応する学習可能な埋め込みを用いていたが，Riou ら [60] はさらに CLAP テキスト埋め込

みと FiLM による条件付けを採用することで，自由形式のテキスト記述（例：「acoustic guitar」や「electric piano」）により楽器を指定できるようになった．具体的には，テキスト特徴量から各層のスケールパラメータ γ とシフトパラメータ β を生成し，予測器の中間層に対してアフィン変換を適用する．これにより，学習時に含まれていない楽器に対してもゼロショット検索が可能となり，ベースライン手法を大きく上回る性能を示した．

これらの研究は，FiLM によるテキスト条件付けが楽器レベルでの特徴抽出や検索タスクにおいて有効であることを実証している．特に，CLAP などの事前学習済みテキスト・音響対照学習モデルから得られるテキスト埋め込みは，楽器の音響的特性を捉えた意味的な表現空間を提供し，FiLM による条件付けによってこのテキスト情報を効果的に特徴抽出プロセスに組み込むことができる．また，テキスト埋め込みの意味空間における類似性により，学習時に含まれていない楽器に対してもゼロショット対応が可能となり，単一のモデルで多様な楽器に対応できるため，対象楽器数の増加に伴う計算量の増加を抑制できる．

2.7 本章のまとめ

本章では，InMSRL の従来手法および関連研究について述べた．2.2 節では，InMSRL の従来手法である *Clean* 手法，*Cascade* 手法，*Direct* 手法について述べた．2.3 節では，従来手法の楽曲間類似度表現性能および知覚的類似度表現性能について述べた．2.4 節では，音源分離で広く用いられている U-Net について述べた．2.5 節では，知覚的類似度ラベルを用いた学習手法について述べた．2.6 節では，テキスト表現による特徴量抽出手法について述べた．

第3章　人間の知覚および知見を活用した学習戦略

3.1　はじめに

本章では，InMSRL における知覚的類似度の表現不足という課題に対処するための学習戦略について述べる．3.2 節では，提案する学習手法について述べる．3.3 節では，提案手法の実験的評価について述べる．最後に，3.4 節では，本章のまとめについて述べる．

3.2　提案する学習戦略

本節では，本章で提案する学習手法について述べる．本研究では，InMSRL における楽曲間類似度および知覚的類似度の表現不足という課題に対処するため，信号処理に基づく楽曲間類似度表現手法（Signal-Processing-based Music Similarity Representation; SP-MSR）を事前学習に導入し，その後，人間が付与した知覚的類似度ラベルを用いて fine-tuning する Perception-Aware Fine-Tuning（PAFT）を適用する二段階の学習戦略を提案する．

従来の InMSRL 手法では，自己教師あり学習における類似度基準として「同一楽曲内のセグメント同士は異なる楽曲のセグメント同士より類似している」という楽曲内類似度改定が用いられてきた．しかし，この基準は楽曲間類似度という本来の目的に対して単純すぎるため，人間の知覚的類似度を十分に表現できないという問題があっ

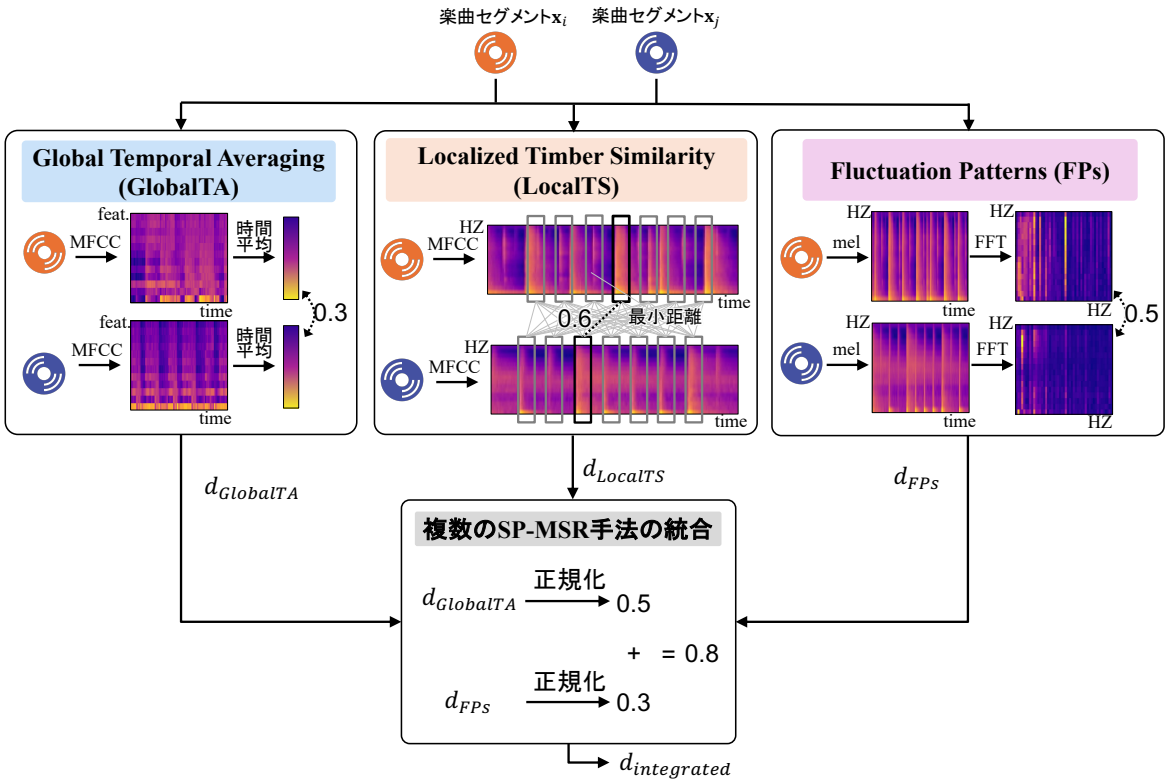


図 3.1: 本研究で導入する信号処理に基づく楽曲間類似度表現手法（SP-MSR: Signal-Processing-based Music Similarity Representation）の概要.

た．本研究では，人間の音楽的知見に基づいて設計された信号処理手法と，実際の人間の知覚データを組み合わせることで，この問題の解決を目指す.

3.2.1　事前学習で導入する信号処理による楽曲間類似度表現手法

本研究では，事前学習の類似度基準として，以下の 3 つの SP-MSR 手法を導入する．図 3.1 に導入する SP-MSR の概要を示す．これらの手法は，人間の音楽的知見に基づいて設計されており，従来の楽曲内類似度では捉えられない複雑な類似度特徴をモデルに学習させることを目的としている.

Global Temporal Averaging (GlobalTA)

Global Temporal Averaging (GlobalTA) は, 畳み込みニューラルネットワーク（CNN）の最終層におけるプーリング処理などで用いられる手法であり [39, 41, 61]，時間軸に沿った特徴を一様に重み付けすることで楽曲セグメントの大域的な音色類似度を捉えることができると考えられる．

時間長 t の i 番目の楽曲セグメント $\boldsymbol{x}_i \in \mathbb{R}^t$ と j 番目の楽曲セグメント $\boldsymbol{x}_j \in \mathbb{R}^t$ の間の類似度を計算する際，まず d 次元の MFCC を計算し，時間方向の平均を適用することで特徴量ベクトル $\boldsymbol{v}_i, \boldsymbol{v}_j \in \mathbb{R}^d$ を各セグメントについて得る．次に，$\boldsymbol{v}_i$ と $\boldsymbol{v}_j$ の間の L2 距離を類似度値として計算する：

$$d_{\mathrm{GlobalTA}}(\boldsymbol{x}_i, \boldsymbol{x}_j) = \|\boldsymbol{v}_i - \boldsymbol{v}_j\|_2 \tag{3.1}$$

GlobalTA は楽曲全体の音色的特性を要約することで，大域的な音色類似パターンを表現できる．

Localized Timbral Similarity (LocalTS)

大域的な音色類似度に加えて，時間軸に沿った局所的な音色類似性も存在すると考えられる．例えば，ドラムパート内のハイハット音が類似している場合などである．このような局所的類似性を捉えるため，本研究では Localized Timbral Similarity (LocalTS) を導入する．

LocalTS に基づく類似度計算方法は以下のとおりである．まず，i 番目の楽曲セグメント $\boldsymbol{x}_i$ と j 番目の楽曲セグメント $\boldsymbol{x}_j$ に対して MFCC を計算し，特徴ベクトル系列 $\boldsymbol{V}_i \in \mathbb{R}^{d\times s}$ および $\boldsymbol{V}_j \in \mathbb{R}^{d\times s}$ を得る．ここで，s は時間フレーム数を表す．次に，局所時間セグメントの窓幅を w，ストライドを n とするスライディングウィンドウ法を用いて，$\boldsymbol{V}_i$ および $\boldsymbol{V}_j$ から局所化された時間的音楽特徴 $\boldsymbol{L}_i \in \mathbb{R}^{d\times w\times l}$ および $\boldsymbol{L}_j \in \mathbb{R}^{d\times w\times l}$ を抽出する．ここで，l はスライディングウィンドウ法により抽出されるセグメント数

を表す．そして，$\boldsymbol{L}_i$ 内の k 番目の局所特徴 $\boldsymbol{l}_{i,k} \in \mathbb{R}^{d \times w}$ と $\boldsymbol{L}_j$ 内の m 番目の局所特徴 $\boldsymbol{l}_{j,m} \in \mathbb{R}^{d \times w}$ の間の L2 距離を，全ての可能な k と m のペア（すなわち合計 l^2 個のペア）について計算する．最後に，全ペアにおける最小 L2 距離を $\boldsymbol{x}_i$ と $\boldsymbol{x}_j$ の間の類似度値として定義する：

$$d_{\text{LocalTS}}(\boldsymbol{x}_i, \boldsymbol{x}_j) = \min_{k,m} \|\boldsymbol{l}_{i,k} - \boldsymbol{l}_{j,m}\|_2 \tag{3.2}$$

LocalTS は音声の局所的な領域における音色特性を解析することで，大域的な平均では失われる細かな楽器特有の音色的類似性を捉えることができる．

Fluctuation Patterns (FPs)

音楽からリズムやテンポに関連する特徴を抽出するための様々な手法が提案されている [62, 63]．その中でも，Fluctuation Patterns (FPs) は周波数帯域における音量変動をモデル化することでリズム特徴を捉える手法として導入されてきた [64, 65, 66]．

FPs に基づく類似度計算方法は以下のとおりである．まず，i 番目の楽曲セグメント $\boldsymbol{x}_i$ と j 番目の楽曲セグメント $\boldsymbol{x}_j$ に対してメルスペクトログラムを計算する．次に，各メル帯域において時間軸に沿って高速フーリエ変換（FFT）を適用し，振幅変調を得ることで，メル周波数ビン数 f，メルスペクトログラムの時間フレーム特徴量行列 s の $\boldsymbol{F}_i \in \mathbb{R}^{f \times s}$ および $\boldsymbol{F}_j \in \mathbb{R}^{f \times s}$ を得る．従来手法では，FPs はメル周波数軸に沿って $\boldsymbol{F}_i$，$\boldsymbol{F}_j$ を平均化することで計算されることが多い [64]．本研究では，メル周波数帯域全体にわたるリズム類似性をより正確に捉えるため，周波数方向の平均を適用せず，$\boldsymbol{F}_i$ と $\boldsymbol{F}_j$ の間の L2 距離を類似度値として定義する：

$$d_{\text{FPs}}(\boldsymbol{x}_i, \boldsymbol{x}_j) = \|\boldsymbol{F}_i - \boldsymbol{F}_j\|_2 \tag{3.3}$$

FPs は人間が知覚する音楽的な表現やリズム感を反映した特徴量を提供し，音楽分析において MFCC と並んで確立された信号処理特徴量として知られている．

複数の SP-MSR 手法の統合

多次元的な SP-MSR 手法を統合することで，より多様で豊かな類似度表現を得ることが望ましい．先行研究 [64] と同様に，本研究では複数の SP-MSR 結果により計算された距離値を統合する手法を導入する．

具体的には，i 番目の楽曲セグメント $\boldsymbol{x}_i$ と j 番目の楽曲セグメント $\boldsymbol{x}_j$ から，異なる SP-MSR 手法 α，β，γ に基づいて類似度値 $s^{(\alpha)}$，$s^{(\beta)}$，$s^{(\gamma)}$ を計算する．同様に，n 個の楽曲セグメントペアに対して α，β，γ に基づく類似度値を計算し，同一の SP-MSR 手法（α，β，または γ）から得られた b 個の類似度値に対して最大値-最小値正規化を適用することで，正規化された値 $s'^{(\alpha)}$，$s'^{(\beta)}$，$s'^{(\gamma)}$ を得る．最後に，統合された類似度値を以下のように定義する：

$$d_{\text{integrated}}(\boldsymbol{x}_i, \boldsymbol{x}_j) = s'^{(\alpha)} + s'^{(\beta)} + s'^{(\gamma)} \tag{3.4}$$

これらの SP-MSR 手法は，GlobalTA 及び LocalTS が音色類似度をモデル化するのに対し，FPs がリズム類似度をモデル化するように設計されており，これらは音楽類似度の知覚において本質的な要素である [67, 68]．複数の手法を組み合わせることで，単一の信号処理手法では捉えられない複合的な音楽的類似性をモデルに学習させることが可能となる．

3.2.2 事前学習

事前学習の概要を図 3.2 に示す．3.2.1 節で述べた SP-MSR 手法は，トリプレット損失（式 2.1）のサンプリング戦略に統合される．具体的には，SP-MSR による類似度基準を用いて以下のようにトリプレットを構成する：

- **アンカー**：基準となる楽曲セグメント
- **ポジティブ**：アンカーとは異なる楽曲のセグメントで，SP-MSR 基準でアンカー

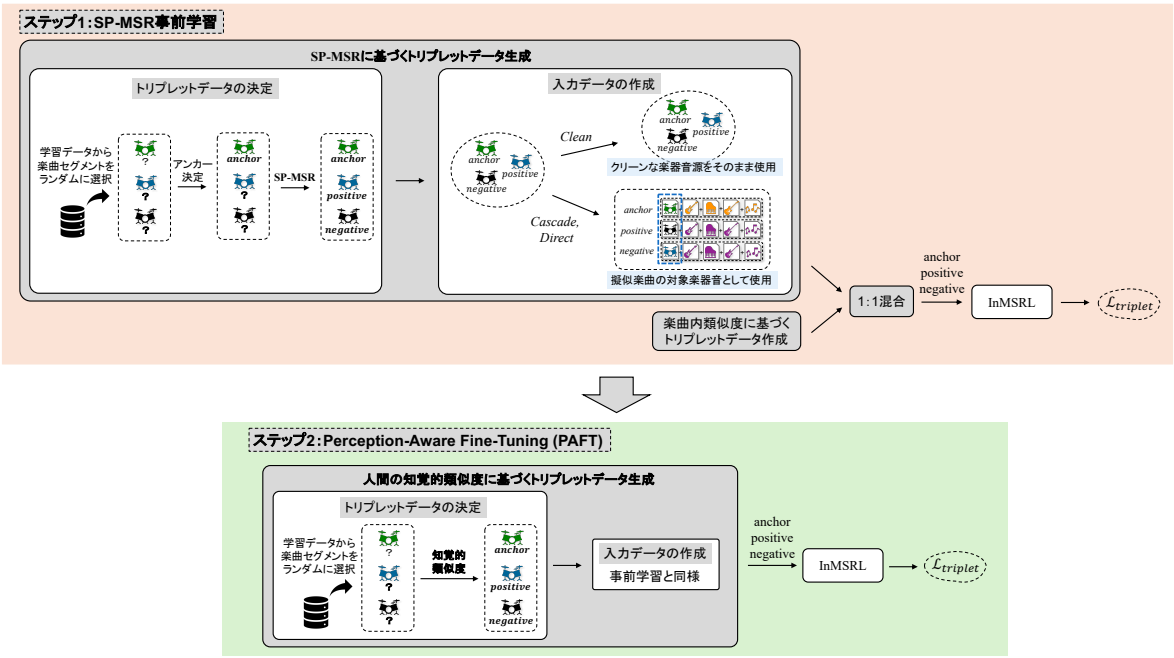


図 3.2: 事前学習および Perception-Aware Fine-Tuning (PAFT) の概要.

に類似していると判断されるセグメント

- **ネガティブ**：アンカーとは異なる楽曲のセグメントで，SP-MSR 基準でアンカーに非類似と判断されるセグメント

このアプローチにより，単純な楽曲内類似度では表現できない，人間の音楽的知見に基づいた複雑な知覚的類似度特徴をモデルに学習させることができる．さらに，SP-MSR 手法のみではなく，従来の楽曲内類似度仮定に基づくトリプレットデータも併用する．具体的には，SP-MSR 基準に基づくトリプレットと楽曲内類似度基準に基づくトリプレットを 1:1 の比率で混合し，学習に用いる．この混合手法により，信号処理的な類似度特徴と楽曲内の類似度特徴の両方を同時に学習することで，より頑健な特徴量表現の獲得を目指す．

加えて，SP-MSR に基づいたトリプレットデータを用いる際，ベースラインモデルとして *Clean* または *Cascade* のどちらを用いるかによって入力データが異なるため，ト

リプレットデータの構築にも違いがある．*Clean* 設定では対象楽器のクリーンなステム音源を，*Cascade* 設定では楽曲音源そのものを入力とするためである．*Clean* に対しては，ステム音源に対し，上記の手順で SP-MSR に基づくトリプレットデータを構築する．*Cascade* に対しては，SP-MSR 手法に基づくトリプレットデータ構成を擬似楽曲内の対象楽器音にのみ適用する．非対象楽器については，従来手法 [39, 41] と同様に，楽曲内類似度尺度に基づいてトリプレットデータを構成する．

3.2.3 Perception-Aware Fine-Tuning (PAFT)

事前学習により獲得された特徴量表現は，信号処理的な類似度基準または楽曲内類似度基準に基づいているが，これらは必ずしも人間が実際に感じる知覚的類似度と一致するとは限らない．そこで本研究では，少量の人手で付与された知覚的類似度ラベルを用いてモデルをファインチューニングする Perception-Aware Fine-Tuning（PAFT）を提案する．

PAFT の概要を図 3.2 に示す．PAFT では，人間が実際に聴取して判断した楽曲間の知覚的類似度ラベルを用いて，事前学習済みモデルを追加学習する．具体的には，人間の判断者が楽曲ペアに対して特定の楽器に着目した類似度判断を行い，その判断結果をラベルとして用いる．評価実験では ABX テスト形式の人間判断データを使用しており，判断者は「楽曲 A が楽曲 B と楽曲 X のどちらにより類似しているか」を特定の楽器に着目して判断する．

PAFT はトリプレット損失によって学習される．そしてそのトリプレットデータは，人間の知覚的類似度ラベルに基づいて構成される：

- **アンカー**：基準となる楽曲セグメント
- **ポジティブ**：人間が知覚的に類似していると判断した楽曲のセグメント
- **ネガティブ**：人間が知覚的に非類似であると判断した楽曲のセグメント

PAFT においても，SP-MSR に基づいた学習と同様に，ベースラインとして *Clean* と *Cascade* のどちらを用いるかにより入力データが異なる．*Clean* に対しては，ステム音源に対し，上記の手順で PAFT のトリプレットデータを構築する．*Cascade* に対しては SP-MSR の場合と同様，上記の人間の知覚的類似度ラベルに基づいたトリプレットデータ構築を対象楽器音にのみ適用する．非対象楽器については，従来手法 [39, 41] と同様に，楽曲内類似度仮定に基づいてトリプレットデータを構成する．

加えて，提案手法では，*Cascade* 設定において PAFT 学習時に，*Cascade-FT* と同様，音源分離モデルと類似度特徴量抽出器を End-to-End で学習する（以後このモデルを ***Cascade-PAFT*** と呼称する）．*Cascade-FT* では，本提案手法において事前学習に相当する，楽曲内類似度に基づく学習において音源分離モデルと類似度特徴量抽出器の End-to-End な Fine-Tuning を導入していた．この End-to-End Fine-Tuning を PAFT において実施することで，楽曲内類似度ではなく人間の知覚的類似度特徴量抽出に音源分離モデルを最適化させる目的がある．これにより，音源分離誤差が知覚的類似度表現に特化したものになり，結果として類似度表現性能が向上することを期待する．

3.3　実験的評価

3.3.1　データセット

本研究の実験評価で使用したデータセットは，従来手法 [39, 40] の実験的評価でも用いられている Slakh データセット [69] である．Slakh データセットは，MIDI 生成された楽曲とその個別楽器ステム音源から構成されている．従来手法での評価に従い，本研究では drums，bass，piano，guitar の 4 つの楽器クラスに着目した．Slakh データセットは，これらの広範な楽器クラス内でさらに細分化されたステム（例: “*Electric Guitar (clean)*”）を提供しているため，Slakh の公式レシピに従い，各クラスに対応するすべてのステムをミックスし，それぞれ「drums」「bass」「piano」「guitar」音源として扱っ

た．これら 4 つの楽器に該当しない残りのすべてのステムは，単一のトラックに統合され，「residuals」としてラベル付けされた．

データセットは合計 2,100 曲の楽曲から構成されており，同一の MIDI ファイルから生成された複数の楽曲グループを含んでいる．本実験では，同一の MIDI ファイルから生成された楽曲を除外し，最終的に 1,200 曲を訓練用，270 曲を検証用，136 曲を評価用として使用した．

加えて，本研究では，橋爪ら [45] が収集した大規模な人間の知覚的類似度を調査した，ABX テスト形式で収集されたデータを使用する．ABX テストでは，参加者に 3 つの対象楽器音の楽曲セグメント X，A，B が提示され，「A と B のどちらが X により類似しているか」という質問に対して回答する．ABX データの詳細は 2.3 節に記述している．

使用する ABX データは，参加者の 75%以上が一貫して同じ選択肢（A または B）を選んだデータのみを使用する．これにより，人間の判断が比較的明確なデータのみを用いることができる．各楽器・条件ごとの ABX データ数と回答数を表 3.1 に示す．

本実験では，この ABX データを 1:1 の割合で分割し，半分を PAFT に，半分を評価に使用した．

3.3.2 実験設定

学習のパラメータについてまとめる．モデルの最適化には Adam [70] を使用した．学習率には，事前学習，PAFT ともに 1×10^{-3} を使用した．バッチサイズには，事前学習，PAFT ともに 64 を使用した．学習のエポック数は，事前学習においては最大 400 で，100 エポックで Early Stopping した．PAFT においては，100 エポック学習した．事前学習における Early Stopping の基準には検証データに対する全体の損失の値を用いた．トリプレット損失のマージンには 0.2 を使用した．

SP-MSR のパラメータについてまとめる．GlobalTA の MFCC の算出にはサンプリ

表 3.1: 評価に使用した ABX データ数と回答数．75%以上の参加者が一貫した回答を示したデータのみを使用した．

指標	楽器			
	drums	bass	piano	guitar
ABX データ数				
全データ (All-Diff)	240	240	240	240
全データ (One-Shared)	240	240	240	240
75%以上一致 (All-Diff)	115	112	106	105
75%以上一致 (One-Shared)	214	194	215	213
回答数				
全回答 (All-Diff)	2421	2429	2424	2425
全回答 (One-Shared)	2408	2422	2425	2412
75%以上一致 (All-Diff)	1163	1128	1083	1085
75%以上一致 (One-Shared)	2163	2959	2159	2134

ングレート 44, 100Hz を使用した．MFCC の出力次元数には 13 次元を用い，0 次元目を除いた 12 次元を用いた．LoTiS において用いた MFCC は TA と同様に算出した．LocalTS における，スライディングウィンドウ法の局所時間窓幅には 8 点，ストライドには 1 点を用いた．FPs のメルスペクトログラムの算出には，サンプリングレートに 44, 100Hz，窓幅 2, 048 点，窓シフト幅 1, 024 点，メル周波数ビン数に 16 点を用いた．FPs の時間方向の高速フーリエ変換の窓幅，窓シフト幅にはメルスペクトログラムの時間次元長を用いた．距離値統合手法の正規化処理における，類似度値の個数は 100 に設定した．

入力音源のパラメータについてまとめる．ネットワークの入力にはスペクトログラムを用いた．サンプリングレートは 44, 100Hz に設定した．事前学習のための事前学習のための楽曲セグメントは，楽曲から学習時と検証時はセグメント長を 3 秒，シフト幅を 3 秒で楽曲を切り出した．PAFT および評価のための楽曲セグメントは，はセグ

メント長 10 秒，シフト幅 10 で切り出で切り出した．スペクトログラムへの FFT 変換においては，FFT 窓幅を 2,048 点，ホップ長を 512 点に設定した．

実験環境についてまとめる．実験には，NVIDIA TITAN RTX，RTX 3090，RTX2080 Ti，または RTX 3090 のいずれかの GPU を一枚使用した．

3.3.3 ベースラインモデル

ベースラインモデルとして以下を用いる．

- *Clean*（2.2.1 節）
- *Cascade*（2.2.2 節）
- *Cascade-FT*（2.2.2 節）

従来手法は楽曲内類似度に基づくトリプレット損失による学習のみを導入している．本実験ではこれら従来手法に対して，楽曲内類似度に基づいた学習に SP-MSR を導入し事前学習とし，その後 PAFT を適用する．

3.3.4 評価指標

本研究では，提案手法の性能を評価するために，知覚的類似度一致率を評価指標として用いる．知覚的類似度一致率は 3.3.1 節で述べた ABX データの All-Diff 条件によって生成されたデータを用いて計算される．具体的には，各 ABX テストにおいて，モデルが X に対して A と B のどちらをより類似していると判断するかを，特徴量間の距離に基づいて決定する．この判断が人間の回答と一致する割合を知覚的類似度一致率として算出する．この評価指標により，モデルが人間の知覚的類似度をどの程度正確に表現できているかを定量的に測定することができる．All-Diff 条件における性能を算出することで，異なる楽曲間の知覚的類似度表現性能を評価することができる．

3.3.5　評価結果

SP-MSR のみでの性能評価

表 3.2 に，SP-MSR 手法の評価結果を示す．表 3.2 に示されているように，“mean w/o mix” のスコアにおいて，クリーンな楽器音を用いた SP-MSR 手法は，機械学習ベースの *Clean* 手法（ベースライン）を上回る性能を達成している．これは，高い解釈性を持ち，特定の音楽的特性を直接捉えることができる信号処理手法が，楽曲内類似度基準に依拠する既存の機械学習手法と比較して，知覚的音楽類似度表現において優れた性能を達成することを示唆している．さらに，SP-MSR 手法間の性能を比較すると，「LocalTS+FPs」や「GlobalTA+FPs」などの複数の類似度指標の組み合わせは，単一の類似度指標の使用を上回る性能を示している．これは，GlobalTA，LocalTS，FPs が異なる音楽的側面に着目しており，多様な類似度指標を組み込むことが音楽類似度表現において効果的であることを示している．

さらに，分離された楽器音を使用した SP-MSR 手法は，mean w/o mix のスコアにおいて，*Cascade* 手法（ベースライン）と同等またはそれ以上の性能を達成している．これは，一般に公開されていないクリーンな楽器音を使用しなくても，SP-MSR 手法が依然として楽曲内類似度基準に依存する機械学習ベースの手法よりも高い知覚的音楽類似度表現性能を達成できることを実証している．しかし，分離された楽器音を使用した場合，クリーンな楽器音を使用した場合と比較して SP-MSR の性能劣化が見られる．これは，音源分離モデルの分離誤差の悪影響によって引き起こされていると考えられる．

PAFT の性能評価

表 3.3 に事前学習のみの場合と PAFT を行った場合の知覚的類似度一致率の評価結果を示す．表 3.3 より，事前学習のみのモデルより PAFT を行った方が性能が高いこ

とがわかり，このことからPAFTの有効性が示唆される．

また，PAFTの有無に関わらず，*Cascade-FT* より *Cascade* の方が性能が高い傾向がある．楽曲内類似度に基づいたトリプレット損失による学習である事前学習において，*Cascade-FT* は *Cascade* より効果的な学習を行えていると考えられる．というのも *Cascade-FT* は *Cascade* より楽曲内類似度表現性能が高いからである [41]．このことから，楽曲内類似度に基づいた事前学習において効率的な学習を行ったとしても，知覚的楽曲間類似度表現性能の向上に繋がらないことが示唆される．

さらに，*Cascade* および *Cascade-FT* において，PAFT時，通常楽曲を用いた場合より，擬似楽曲を用いた場合の方が性能が高いことがわかる．このことから，楽曲音源自体を入力する設定における擬似楽曲の有効性の高さを確認できる．

加えて，*Cascade-FT* における楽器音源分離モデルと類似度特徴量抽出器の同時学習を，PAFT時に導入した *Cascade-PAFT* は，*Cascade* および *Cascade-FT* の両モデルの性能を上回っている．これは，MSSモデルによる分離誤差が後段の特徴抽出器に与える影響を最小化することに加え，人間の嗜好に基づく音楽類似度の観点からネットワーク全体を最適化したことによる結果だと考えられる．このことから，PAFTにおける効率的な学習がさらなる知覚的類似度表現性能の向上に繋がることが示唆される．

SP-MSRの学習への応用による性能評価

SP-MSRをInMSRLの学習に応用した場合の評価結果を表3.4に示す．表3.4における各スコアは，PAFT適用後のスコアである．比較対象は，PAFTのみ（少量の人手による知覚的類似度ラベルのみ）で学習した“事前学習なし”と，楽曲内類似度のみに基づく事前学習を行う既存手法（*Clean* および *Cascade*）を表す“楽曲内類似度”である．

まず，クリーンな楽器音を入力とする *Clean* モデルの評価結果を分析する．表3.4より，事前学習を行ったモデルは，PAFTのみを適用した“事前学習なし”よりも高いス

コアを達成していることが分かる．これは，PAFT における性能向上に対して事前学習が大きく寄与することを示している．さらに，SP-MSR に基づく類似度で事前学習したモデルは，“事前学習なし” および 楽曲内類似度のみに基づいて事前学習したモデル（“楽曲内類似度”）の双方を上回る．また，複数種類の類似度（例：‘GlobalTA+FPs”，‘LocalTS+FPs w/ 楽曲内類似度”）を統合する手法は，単一の類似度基準のみを用いる手法（例：‘GlobalTA”，‘LocalTS”，‘FPs”）よりも高い性能を示す傾向がある．この結果は，SP-MSR ベースおよび 楽曲内類似度ベースの類似度を含む，異なる基準に基づく複数の類似表現を組み合わせることが有効であることを示唆する．

次に, 楽曲音源自体を入力とする *Cascade* モデルの評価結果を分析する．表 3.4 より，事前学習を行ったモデルは “事前学習なし” を上回っていることが確認できる．さらに *Cascade* モデルでは, SP-MSR ベースの類似度を追加して事前学習した ‘LocalTS+FPs w/ 楽曲内類似度” が，楽曲内類似度のみに基づくモデル（“楽曲内類似度”）と同等，あるいはそれ以上のスコアとなっている．これは，*Cascade* モデルにおいても，知覚楽曲間類似度表現性能の向上に対して SP-MSR ベースの事前学習が有効であることを示している．

加えて，一部の事前学習手法（例：“楽曲内類似度”，‘LocalTS+FPs w/ 楽曲内類似度”）では，*Clean* モデルよりも *Cascade* モデルの方が高いスコアを記録する．これは，同一楽曲間の音楽類似度を過度に学習してしまう影響による可能性がある．分離後の楽器音には分離誤差が含まれ，それが楽器特徴の一部をマスクすると考えられるため，クリーンな楽器音を用いる場合と比べて，事前学習時により多様な楽器特徴を学習しやすくなる可能性がある．

SP-MSR のみの性能と学習へ応用した場合の性能の比較

提案手法は SP-MSR に基づく類似度を活用している一方で，SP-MSR 自体は学習を必要としない信号処理手法である点に留意する必要がある．そこで，学習を導入する

ことで SP-MSR 単体を上回る性能が得られるかを検証する．表 3.5 に，SP-MSR のみを用いる手法と，提案する SP-MSR ベース InMSRL 手法の性能比較を示す．表 3.5 より，クリーンな楽器ステムおよび分離後の楽器ステムのいずれを用いる場合においても，SP-MSR ベース InMSRL モデルは SP-MSR 単体手法を上回る傾向がある．これは，信号処理のみでは導入が困難な楽曲内類似度や PFT に得ら得られる有益な情報を利用することができることが関係していると考えられる．また，SP-MSR は分離後の楽器ステムを用いると性能が低下する一方で，SP-MSR ベース InMSRL モデルでは，クリーンな楽器ステムを用いた場合と比較してそのような性能低下は確認されない．信号処理ベース手法では，音源分離モデルに起因する分離誤差が性能へ直接的に影響すると考えられる．これに対し，機械学習ベースのモデルでは，先行研究で提案されている手法により，これらのアーティファクトに対する頑健性を獲得できることが示されている [41]．以上より，提案手法は，信号処理ベース手法と機械学習ベース手法の双方の利点を組み合わせることが可能である．

3.4 本章のまとめ

本章では，InMSRL における知覚的類似度の表現不足という課題に対処するための学習戦略について述べた．3.2 節では，事前学習で導入する信号処理による楽曲間類似度表現手法（SP-MSR）について述べた．3.3 節では，提案手法の実験的評価について述べた．

表 3.2: SP-MSR 手法の評価結果．表記 $[*, *]$ は，Clopper–Pearson 法 [71] により算出した 95% 信頼区間を表す．クリーンな楽器音を用いるベースラインは，S4 で事前学習した *Clean* を指し，分離した楽器音を用いるベースラインは，S4 で事前学習した *Cascade* を指す．SP-MSR 手法で用いる分離楽器音は，*Cascade* の音源分離モデルによって分離したものである．mean w/o mix は，楽器ソースのみを対象として算出した評価スコアの平均値を表す．**太字**は最も良い評価値を示し，下線は二番目に良い値を示す．

Method	drums	bass	piano	guitar	mix	mean w/o mix
	input: clean instrument sounds					
Baseline	63.11 [60.27,65.89]	55.14 [52.18,58.07]	61.59 [58.62,64.50]	65.53 [62.62,68.36]	57.52 [53.80,61.19]	61.34
GlobalTA	66.04 [63.23,68.76]	72.25 [69.54,74.85]	62.51 [59.55,65.40]	64.24 [61.31,67.10]	60.76 [57.06,64.37]	66.26
LocalTS	62.77 [59.92,65.55]	61.97 [59.06,64.81]	68.98 [66.12,71.72]	66.73 [63.84,69.53]	54.57 [50.83,58.28]	65.11
FPs	63.20 [60.35,65.98]	72.61 [69.90,75.19]	69.71 [66.88,72.44]	61.47 [58.50,64.38]	60.48 [56.78,64.09]	66.75
LocalTS+FPs	67.84 [65.07,70.52]	71.10 [68.36,73.73]	**71.93** [69.15,74.59]	**67.19** [64.31,69.98]	**62.73** [59.06,66.29]	**69.52**
GlobalTA+FPs	**68.01** [65.25,70.69]	**73.32** [70.63,75.88]	65.93 [63.02,68.75]	63.32 [60.37,66.19]	60.48 [56.78,64.09]	67.65
	input: separated instrument sounds					
Baseline	**69.56** [59.13,64.79]	62.32 [64.91,70.45]	57.34 [53.96,59.94]	66.73 [62.24,68.00]	–	63.99
GlobalTA	63.54 [60.70,66.31]	63.74 [60.86,66.55]	64.91 [61.99,67.76]	66.64 [63.74,69.44]	–	64.71
LocalTS	57.44 [54.54,60.30]	60.28 [57.36,63.15]	60.85 [57.87,63.77]	**70.23** [67.41,72.94]	–	62.20
FPs	60.53 [57.66,63.36]	62.23 [59.33,65.07]	**66.11** [63.21,68.93]	57.79 [54.79,60.75]	–	61.67
LocalTS+FPs	61.91 [59.05,64.71]	60.73 [57.81,63.59]	62.97 [60.02,65.86]	67.65 [64.78,70.43]	–	63.32
GlobalTA+FPs	66.29 [63.50,69.01]	**64.27** [61.40,67.07]	65.74 [62.83,68.57]	64.61 [61.68,67.46]	–	**64.98**

表 3.3: 知覚的類似度一致率の評価結果．“w/o PAFT” は S4 類似度のみで学習したモデルのスコアを示し，“w/ PAFT” は PAFT により学習したモデルのスコアを示す．$[*, *]$ は Clopper–Pearson 法 [71] により算出した 95% 信頼区間を表し，$\underset{\pm *}{*}$ は 3 回の学習実行から得られた平均値と標準偏差を表す（PAFT に利用可能なデータが限られていることに起因するモデル挙動の不安定性を強調するためである）．“mean” 列は drums，bass，piano，guitar の平均評価スコアを示す．“PAFT data” 列は PAFT 時にモデルへ入力したデータを示す．“分離損失” 列は分離損失の使用有無を示す．**太字**は最も良い評価値を示し，下線は二番目に良い値を示す．“Gray” のテキストはアブレーションスタディで用いたスコアを示す．

Method	分離損失（事前学習）	分離損失（PAFT）	PAFT data	Score (%) drums	bass	piano	guitar	mean
事前学習のみ								
Clean	×	–	clean	63.11 [60.27,65.89]	55.14 [52.18,58.07]	61.59 [58.62,64.50]	65.53 [62.62,68.36]	61.34
Cascade	×	–	pseudo	**69.56** [66.83,72.20]	**62.32** [59.42,65.16]	57.34 [54.33,60.31]	**66.73** [63.84,69.53]	**63.99**
Cascade-FT	✓	–	pseudo	62.25 [59.40,65.05]	61.44 [58.52,64.29]	**62.42** [59.46,65.31]	58.53 [55.53,61.48]	61.16
事前学習 + PAFT								
Clean	×	×	clean	61.81 ±5.62	71.89 ±17.20	58.36 ±2.64	66.10 ±3.67	64.54
Cascade	×	×	pseudo	**71.09** ±0.75	75.50 ±2.58	60.45 ±5.52	**76.55** ±4.62	70.90
Cascade	×	×	normal	69.53 ±3.07	73.81 ±5.42	64.22 ±0.80	62.99 ±2.72	67.64
Cascade-FT	✓	×	pseudo	69.69 ±2.91	68.75 ±3.70	59.75 ±3.68	73.45 ±4.90	67.91
Cascade-FT	✓	×	normal	69.77 ±4.26	71.65 ±2.77	60.19 ±2.64	64.59 ±0.59	66.55
Cascade-PAFT	×	✓	pseudo	70.54 ±3.49	**76.30** ±4.60	**64.65** ±4.62	75.80 ±0.16	**71.83**

表 3.4: 楽曲内類似度および SP-MSR の知識で事前学習した後に PAFT を実施した InMSRL モデルに対する，知覚的類似性表現性能の評価結果．表には，3 回の学習実行における結果の平均値と標準偏差を示す．mean w/o mix は，楽器ソースのみを対象として算出した評価スコアの平均値を表す．*Cascade-PAFT* の結果は，*Clean* において高い性能を達成したものを選択した．**太字**は最も良い評価値を示し，下線は二番目に良い値を示す．

Triplet sampling method during pretraining	楽曲内類似度	drums	bass	piano	guitar	mix	mean w/o mix
Baseline: *Clean*							
事前学習なし	×	62.56 ±5.32	69.56 ±2.19	60.98 ±2.69	56.12 ±2.99	64.84 ±3.36	62.30
GlobalTA	×	62.25 ±5.91	**80.08** ±1.47	60.19 ±1.06	61.68 ±4.57	68.13 ±2.52	66.05
LocalTS	×	66.51 ±3.72	74.06 ±7.62	**61.68** ±0.91	67.99 ±6.81	**69.60** ±3.03	67.56
FPs	×	**69.69** ±3.78	77.19 ±8.30	57.05 ±3.79	61.76 ±5.10	63.34 ±3.49	66.42
LocalTS+FPs	×	61.01 ±4.57	73.33 ±1.87	58.71 ±3.07	**70.34** ±4.64	65.02 ±3.74	65.85
GlobalTA+FPs	×	66.67 ±5.91	79.44 ±4.66	56.08 ±4.50	69.02 ±5.23	62.09 ±2.85	**67.80**
楽曲内類似度	✓	61.81 ±5.62	71.89 ±17.20	58.36 ±2.64	66.10 ±3.67	60.07 ±0.84	64.54
GlobalTA	✓	62.40 ±2.93	77.11 ±2.78	**67.54** ±4.17	66.76 ±9.46	**68.68** ±3.96	68.45
LocalTS	✓	66.67 ±4.36	71.17 ±8.07	62.38 ±4.33	70.81 ±5.23	67.40 ±9.46	67.76
FPs	✓	**67.13** ±4.40	78.55 ±3.76	64.57 ±1.46	73.54 ±5.99	65.57 ±5.42	70.95
LocalTS+FPs	✓	66.69 ±1.75	80.00 ±2.08	64.48 ±8.05	**75.99** ±0.98	63.74 ±0.95	**71.84**
GlobalTA+FPs	✓	66.04 ±7.08	**82.49** ±1.79	60.63 ±2.73	72.79 ±4.09	68.32 ±6.97	70.49

Triplet sampling method during pretraining	drums	bass	piano	guitar	mean w/o mix
Baseline: *Cascade-PAFT*					
事前学習なし	64.50 ±5.27	58.40 ±3.55	53.81 ±0.95	55.55 ±3.02	58.07
楽曲内類似度	70.54 ±3.49	76.30 ±4.60	64.65 ±4.62	**75.80** ±0.16	71.83
FPs w/ 楽曲内類似度	70.47 ±1.63	78.15 ±0.69	51.09 ±1.34	73.26 ±2.12	68.24
LocalTS+FPs w/ 楽曲内類似度	**72.03** ±0.70	**83.94** ±0.70	60.19 ±3.04	72.41 ±3.17	**72.14**
GlobalTA+FPs w/ 楽曲内類似度	70.23 ±2.64	71.89 ±3.63	**64.92** ±1.52	72.32 ±4.17	69.84

表 3.5: SP-MSR のみの時の評価結果と SP-MSR を学習に使用した場合の評価結果の比較．SP-MSR としては “LocalTS + FPs” を使用．学習に応用する場合は S4 と併用する．各楽器音での結果を平均した値を示す．**太字**は最も良い評価値を示す．

Method	clean instrument scenario	separated instrument scenario
SP-MSR	69.36	$62.63_{\downarrow 6.73}$
ML-Based Method	**71.84**	$\mathbf{72.14}_{\uparrow \mathbf{0.30}}$

第4章　テキスト表現による楽器指定

4.1　はじめに

本章では，従来の InMSRL 手法における計算量の増加および未知楽器への非対応という課題に対処するため，テキスト表現による楽器指定手法について述べる．4.2 節では，提案手法のネットワーク構造について述べる．4.3 節では，提案手法の学習手法について述べる．4.4 節では，提案手法の実験的評価について述べる．最後に，4.5

4.2　ネットワーク構造

本節では，提案手法のネットワーク構造について述べる．図 4.1 にネットワークの概要を示す．提案手法は，2.2.3 節で述べた *Direct* 手法と類似した構造を持ち，2.4 節で述べた U-Net [47] と同様のエンコーダ・デコーダ構造を採用している．ただし，従来手法と大きく異なる点は，楽器指定をテキスト表現によって行い，FiLM [55] を用いてネットワーク全体を条件付ける点である．

4.2.1　全体構造

提案手法のネットワークは，以下の 4 つの主要要素から構成される：

- テキスト特徴量抽出器：楽器名などの自然言語記述からテキスト特徴量を抽出
- 類似度特徴量抽出器：U-Net のエンコーダにあたり，混合楽曲音源から中間特徴

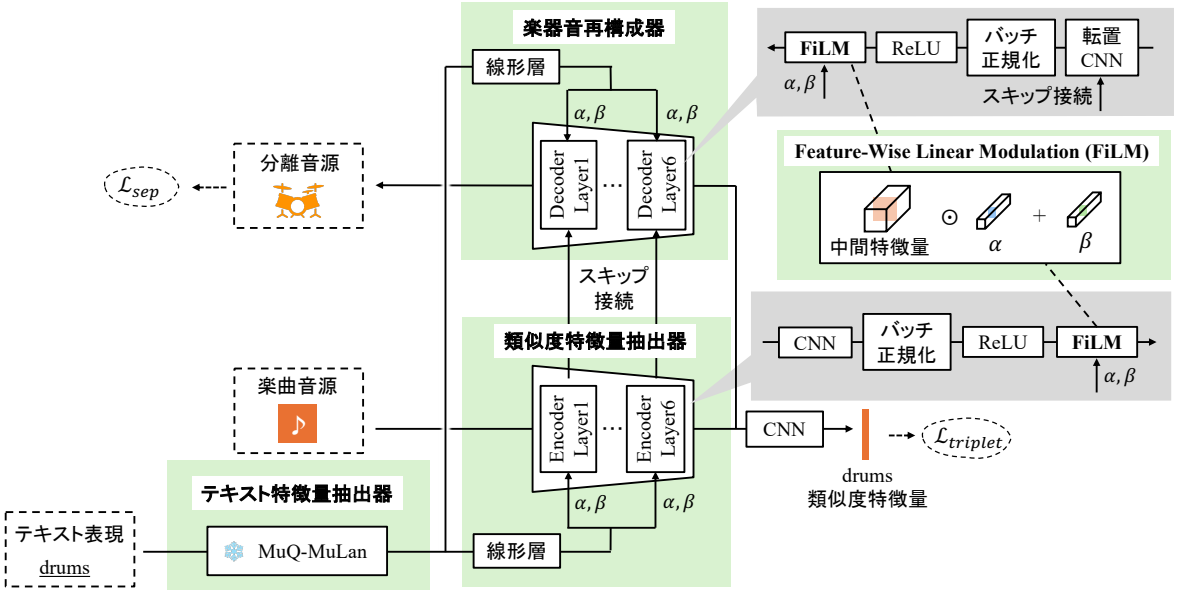


図 4.1: テキスト表現による楽器指定を導入した提案手法のネットワーク構造の概要.

量表現を抽出

- 楽器音再構成器：U-Net のデコーダにあたり，中間特徴量表現から分離音マスクを生成
- FiLM 層：テキスト特徴量に基づいてエンコーダ・デコーダを条件付け

入力は混合楽曲音源そのものであり，音源分離を経ることなく直接処理される．類似度特徴量抽出器からは対象楽器の類似度特徴量が，楽器音再構成器からは対象楽器の分離音が出力される．

4.2.2　テキスト特徴量抽出器

テキスト特徴量抽出器には，2.6 節で述べた MuQ-MuLan [54] の事前学習済みテキストエンコーダを用いる．MuQ-MuLan は，大規模なテキスト・音響対照学習により獲得された頑健なテキスト表現を持つ．楽器名（例：「piano」，「drums」）を入力とし，d_t

次元のテキスト特徴量ベクトル $\boldsymbol{c} \in \mathbb{R}^{d_t}$ を出力する．このテキスト特徴量は，FiLM 層を通じてエンコーダ・デコーダの各層に条件情報として伝達される．

4.2.3 FiLM による条件付け

テキスト特徴量抽出器から得られたテキスト特徴量 $\boldsymbol{c}$ は，2.6.2 節で述べた FiLM [55] を用いてエンコーダ・デコーダの各層を条件付けるために使用される．FiLM は，特徴量に対してアフィン変換（スケーリングとシフト）を適用することで，外部条件に基づいたネットワークの動作の変調を可能にする手法である．具体的には，各層における特徴マップ $\boldsymbol{F}$ に対して，テキスト特徴量 $\boldsymbol{c}$ から生成されるスケールパラメータ $\gamma(\boldsymbol{c})$ およびシフトパラメータ $\beta(\boldsymbol{c})$ を用いて，以下の変換を適用する：

$$\boldsymbol{F}' = \gamma(\boldsymbol{c}) \odot \boldsymbol{F} + \beta(\boldsymbol{c}). \tag{4.1}$$

この FiLM による条件付けにより，単一のネットワークで複数の楽器に対応できる．従来手法では楽器ごとに独立した特徴量次元またはモデルを用意する必要があったが，提案手法ではテキスト表現により楽器を指定するため，モデルサイズの増加を抑制できる．また，MuQ-MuLan のテキストエンコーダは大規模なテキスト・音響対照学習により獲得された頑健な表現を持つため，学習時に含まれていない楽器名に対してもある程度対応できることが期待される．

4.2.4 類似度特徴量抽出器

類似度特徴量抽出器は，U-Net のエンコーダ部分にあたり，混合楽曲音源のスペクトログラムを入力とし，段階的にダウンサンプリングしながら高次の特徴量表現を抽出する．各エンコーダ層では，畳み込み処理の後に FiLM 層が適用され，テキスト特徴量 $\boldsymbol{c}$ に基づいた特徴量の変調が行われる．

テキスト特徴量 $\boldsymbol{c}$ から全エンコーダ層分の FiLM パラメータ（スケールおよびシフト）を一括して生成するため，単一の線形層を用いる．この線形層の出力は各層ごとに分割され，エンコーダ層 l の FiLM パラメータとして使用される．具体的には，エンコーダ層 l における中間特徴量 $\boldsymbol{F}_l$ に対して，以下の変換が適用される：

$$\boldsymbol{F}'_l = \gamma_l(\boldsymbol{c}) \odot \boldsymbol{F}_l + \beta_l(\boldsymbol{c}), \tag{4.2}$$

エンコーダの最終層からは，時間・周波数の両方向にダウンサンプリングされた特徴量が出力される．この特徴量を時間軸方向に平均化し，さらに線形層で処理することで，128 次元の類似度特徴量ベクトル $\boldsymbol{z} \in \mathbb{R}^{128}$ を得る．この特徴量ベクトルは，指定された楽器に対応する楽曲間類似度表現として用いられる．

4.2.5　楽器音再構成器

楽器音再構成器は，U-Net のデコーダ部分にあたり，エンコーダの中間層特徴量をスキップ接続を通じて結合しながら，段階的にアップサンプリングを行い，入力スペクトログラムと同じサイズの分離音マスク $\boldsymbol{M} \in \mathbb{R}^{F \times T}$ を生成する．ここで，F は周波数ビン数，T は時間フレーム数である．

類似度特徴量抽出器と同様に，各デコーダ層にも FiLM 層が適用され，テキスト特徴量 $\boldsymbol{c}$ による条件付けが行われる．類似度特徴量抽出器と同様に，テキスト特徴量 $\boldsymbol{c}$ から全デコーダ層分の FiLM パラメータを一括して生成するため，単一の線形層を用いる．この線形層の出力は各デコーダ層ごとに分割され，それぞれの層のスケールパラメータおよびシフトパラメータとして使用される．

出力された分離音マスク $\boldsymbol{M}$ と入力混合楽曲のスペクトログラム $\boldsymbol{S}_{\text{mix}} \in \mathbb{R}^{F \times T}$ のアダマール積（要素ごとの積）を計算することで，目的楽器の分離音スペクトログラム $\boldsymbol{S}_{\text{sep}}$ を得る：

$$\boldsymbol{S}_{\text{sep}} = \boldsymbol{M} \odot \boldsymbol{S}_{\text{mix}}. \tag{4.3}$$

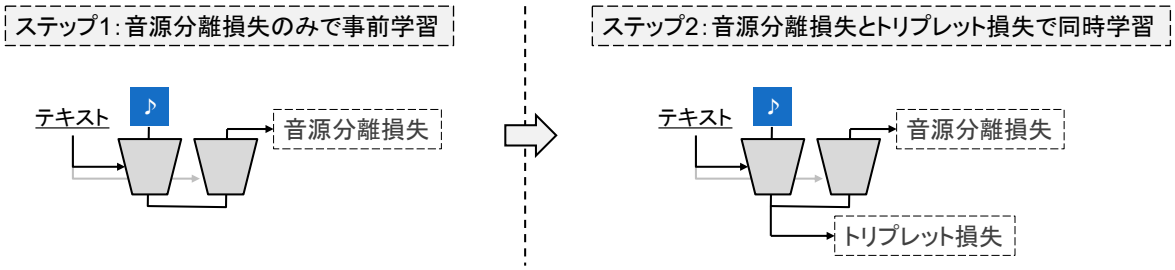


図 4.2: 提案手法の学習手法の概要.

4.3 学習手法

本節では，提案手法の学習手法について述べる．図 4.2 に提案手法の学習方法の概要を示す．提案手法の学習は，二段階の学習戦略を採用している：(1) 分離音の再構成損失による事前学習，(2) 分離損失とトリプレット損失による同時学習.

4.3.1 事前学習：分離音の再構成損失

第一段階の事前学習では，音源分離タスクを通じて，ネットワークがテキスト条件に応じた適切な楽器音分離を学習する．具体的には，楽曲 i に含まれる各楽器 k のステム音源 $\boldsymbol{x}_{i,k}$ と，それらを混合した混合音源 $\boldsymbol{x}_{i,\mathrm{mix}} = \sum_k \boldsymbol{x}_{i,k}$ を用意する．楽器 k を指定するテキスト（例：「drums」）をテキスト特徴量抽出器に入力し，テキスト特徴量 $\boldsymbol{c}_k$ を得る．次に，混合音源 $\boldsymbol{x}_{i,\mathrm{mix}}$ とテキスト特徴量 $\boldsymbol{c}_k$ をネットワークに入力し，楽器音再構成器から楽器 k の分離音 $\hat{\boldsymbol{x}}_{i,k}$ を得る.

事前学習の損失関数は，予測された分離音 $\hat{\boldsymbol{x}}_{i,k}$ と真の分離音 $\boldsymbol{x}_{i,k}$ の間の再構成誤差として定義される：

$$\mathcal{L}_{\mathrm{reconst}} = \|\boldsymbol{x}_{i,k} - \hat{\boldsymbol{x}}_{i,k}\|_1, \tag{4.4}$$

ここで，$\|\cdot\|_1$ は L1 ノルムを表す.

この事前学習により，ネットワークはテキスト条件に応じて適切な楽器音を分離する

能力を獲得する．特に，FiLM 層を通じたテキスト条件付けにより，単一のネットワークで複数の楽器に対応できる表現が学習される．

4.3.2　分離損失とトリプレット損失による同時学習

第二段階の学習では，分離損失とトリプレット損失を同時に最適化することで，音源分離性能と類似度表現性能の両方を向上させる．学習データとして，2.2.3 節で述べた擬似楽曲を用いる．

具体的な学習手順は以下の通りである：

1. トリプレット損失の学習のために，2.2.3 節で述べたアンカー・ポジティブ・ネガティブの 3 つの擬似楽曲 $\boldsymbol{x}_{\text{anchor}}$ $\boldsymbol{x}_{\text{positive}}$ $\boldsymbol{x}_{\text{negative}}$ を生成する．
2. 楽器 k を指定するテキスト特徴量 $\boldsymbol{c}_k$ をネットワークに入力し，各擬似楽曲から類似度特徴量および分離音を得る．アンカー擬似楽曲からは類似度特徴量 $\boldsymbol{z}_k$ および分離音 $\hat{\boldsymbol{x}}_k$ を，ポジティブ擬似楽曲からは類似度特徴量 $\boldsymbol{z}_k^+$ および分離音 $\hat{\boldsymbol{x}}_k^+$ を，ネガティブ擬似楽曲からは類似度特徴量 $\boldsymbol{z}_k^-$ および分離音 $\hat{\boldsymbol{x}}_k^-$ を得る．
3. 分離損失 $\mathcal{L}_{\text{sep}}$ を，アンカー・ポジティブ・ネガティブの全ての擬似楽曲から予測された分離音と真のステム音源の間の再構成誤差として計算する：

$$\mathcal{L}_{\text{sep}} = \sum_{k=1}^{K} \left(\|\boldsymbol{x}_{i_k,k} - \hat{\boldsymbol{x}}_k\|_1 + \|\boldsymbol{x}_{i_k,k}^+ - \hat{\boldsymbol{x}}_k^+\|_1 + \|\boldsymbol{x}_{j_k,k}^- - \hat{\boldsymbol{x}}_k^-\|_1 \right). \tag{4.5}$$

4. トリプレット損失 $\mathcal{L}_{\text{triplet}}$ を計算する．トリプレット損失は，同一楽曲内の特徴は類似し，異なる楽曲間の特徴は離れるように学習するための損失関数であり，以下のように定義される：

$$\mathcal{L}_{\text{triplet}} = \sum_{k=1}^{K} \max(0, d(\boldsymbol{z}_k, \boldsymbol{z}_k^+) - d(\boldsymbol{z}_k, \boldsymbol{z}_k^-) + \alpha), \tag{4.6}$$

ここで，$d(\cdot,\cdot)$ は距離関数（コサイン距離など），α はマージンパラメータである．

5. 最終的な損失関数は，分離損失とトリプレット損失の加重和として定義される：

$$\mathcal{L}_{\text{total}} = \lambda_{\text{sep}}\mathcal{L}_{\text{sep}} + \lambda_{\text{triplet}}\mathcal{L}_{\text{triplet}}, \tag{4.7}$$

ここで，λ_{sep} および λ_{triplet} は，各損失の重要度を調整するハイパーパラメータである．

この同時学習により，音源分離タスクが補助的な正則化として機能し，特徴量分離性能の向上が期待できる．また，擬似楽曲を用いることで，各楽器の特徴量が対応するステム音源の特徴に近づくように学習されるため，混合音源から各楽器の類似度特徴を適切に分離して抽出できるようになる．

4.4 実験的評価

4.4.1 データセット

実験的評価で使用したデータセットは，3.3.1 節の実験と同様に，Slakh データセット [69] を用いる，Slakh データセットは，MIDI 生成された楽曲とその個別楽器ステム音源から構成されている．Slakh データセットには，129 種類の楽器区分のステムが用意されており，129 種類の楽器区分は 16 種類のさらに大まかな上位の楽器区分に属するという，階層的な構造を成した楽器区分ラベルが付与されている．ここで，16 種類の上位の楽器区分を上位楽器区分，129 種類の下位の楽器区分を下位楽器区分と呼称する．

本実験ではこれら上位楽器区分および下位楽器区分を評価対象の楽器として用いる．下位楽器区分の音源にはすでに Slakh データセットで提供されているステム音源を用い，上位楽器区分の音源には対象楽曲における配下の下位楽器区分音源を全て統合したものを用いる．加えて，従来手法との性能比較のために，3.3.1 節にて述べた drums, bass，piano，guitar という上位楽器区分に含まれる 4 つの楽器のみにおける性能評価も行う．すなわち本実験では，以下の 3 つ楽器条件での評価を行う．

- 上位楽器区分における drums, bass, piano, guitar の 4 種類の楽器（Slakh-Core と呼称）
- 上位楽器区分に含まれる 16 種類の楽器（Slakh-Super と呼称）
- 下位楽器区分に含まれる 129 種類の楽器（Slakh-Sub と呼称）

データセットには全 2,100 曲の楽曲が含まれており，同一の MIDI ファイルから生成された複数の楽曲グループも含まれている．本実験では，同一の MIDI ファイルから生成された楽曲を除外した 1,710 曲を，855 曲を学習，400 曲を検証，455 曲を評価に使用した．

学習対象楽器の選択

下位楽器区分には 129 種類の楽器が存在するが，全ての楽器が均等に十分量含まれているとは限らない．また，学習に用いていない条件の楽器に対する評価を行うためには，学習データには存在しないが評価データには存在する楽器が必要となる．そこで，各楽器に対して十分な楽曲数での学習・評価の実現と，未学習楽器に対する評価のために，学習および評価および評価対象楽器の選択を行う．

まず，学習用の楽器の選択手法は以下である．

1. 学習に使用しない楽器を意図的に用意する．本実験では下位楽器区分において 20 個の楽器を学習非対象とした．
2. 学習に用いる楽曲において，目的楽器の音源が含まれている楽曲数が 10 曲以上である楽器のみを選択する．

次に，評価用の楽器の選択手法は以下である．

1. 評価に用いる楽曲において，目的楽器の音源が含まれている楽曲数 N を調べる．

2. N 曲の目的楽器の音源が含まれている楽曲において，評価時の楽曲セグメントの秒数 s において有音のセグメント数を調べる．そして，有音判定されたセグメント数が一楽曲あたり 10 セグメント存在する楽曲数 N_{sound} を調べる．
3. N_{sound} が 10 曲以上の楽器のみを選択する．

4.4.2 実験設定

学習のパラメータについてまとめる．モデルの最適化には Adam [70] を使用した．学習率には，事前学習，同時学習ともに 1×10^{-3} を使用した．バッチサイズには，事前学習，同時学習ともに 64 を使用した．学習のエポック数は，事前学習，同時学習ともに，最大 $1,000$ で，100 エポックで Early Stopping した．Early Stopping の基準には検証データに対する全体の損失の値を用いた．トリプレット損失のマージンには 0.2 を使用した．

入力音源のパラメータについてまとめる．ネットワークの入力にはスペクトログラムを用いた．サンプリングレートは 44100Hz に設定した．楽曲セグメントは，楽曲から学習時と検証時はセグメント長を 3 秒，シフト幅を 3 秒に設定し，評価時はセグメント長を 10 秒，シフト幅を 10 秒に設定した．スペクトログラムへの FFT 変換においては，FFT 窓幅を 2048 点，ホップ長を 512 点に設定した．

実験環境についてまとめる．実験には，NVIDIA TITAN RTX，RTX 3090，RTX2080 Ti，または RTX 3090 のいずれかの GPU を一枚使用した．

4.4.3 ベースライン

提案手法の比較対象には，提案手法と同じく単一のモデルで複数楽器の特徴量を出力する枠組みである *Direct* モデルと，関連研究である Riou ら [60] のテキストによるステム選択モデルと同様の，エンコーダのみによる特徴量抽出モデルを選択した．エ

ンコーダのみの特徴量抽出モデルは，提案手法の音源分離用のデコーダなし，音源分離事前学習なしと同等である．

4.4.4　評価指標

評価指標として，先行研究 [39, 40, 41] で用いられている楽曲 ID 推定精度を使用した．ここで，楽曲 ID 推定精度については，通常テスト楽曲における楽曲 ID 推定スコア（MES-Normal）および擬似テスト楽曲における楽曲 ID 推定スコア（MES-Pseudo）の 2 つの指標を用いた．

通常テスト楽曲における楽曲 ID 推定スコア（MES-Normal）

類似度表現性能を評価するために，先行研究の手法に従い，特徴量による類似度表現を用いた単純な手法による楽曲 ID 推定の精度を用いた．具体的には，全てのテストセグメントが事前に特徴量空間に埋め込まれており，推定対象のテストセグメント以外の全てのセグメントの楽曲 ID が既知であると仮定し，5 近傍法（5NN）を用いてテストセグメントの楽曲 ID を推定した．楽曲 ID 推定精度の計算には，評価データから最大 100 曲を選択し使用した．評価データにおいて 100 曲に満たない楽曲数しか用意できない楽器の評価には，使用可能な全ての楽曲を使用した．

MES-Normal において高い精度は，同一楽曲内のセグメントの特徴ベクトルが互いに近接してクラスタリングされていることを示す．言い換えれば，MES-Normal は楽曲内類似度に基づく類似度の表現性能を評価する．

擬似テスト楽曲における楽曲 ID 推定スコア（MES-Pseudo）

提案手法は，個別楽器に着目した楽曲間類似度特徴表現の学習を目的としている．しかし，MES-Normal では，図 4.3 の上部に示すように，5NN 法における正解ラベルが全

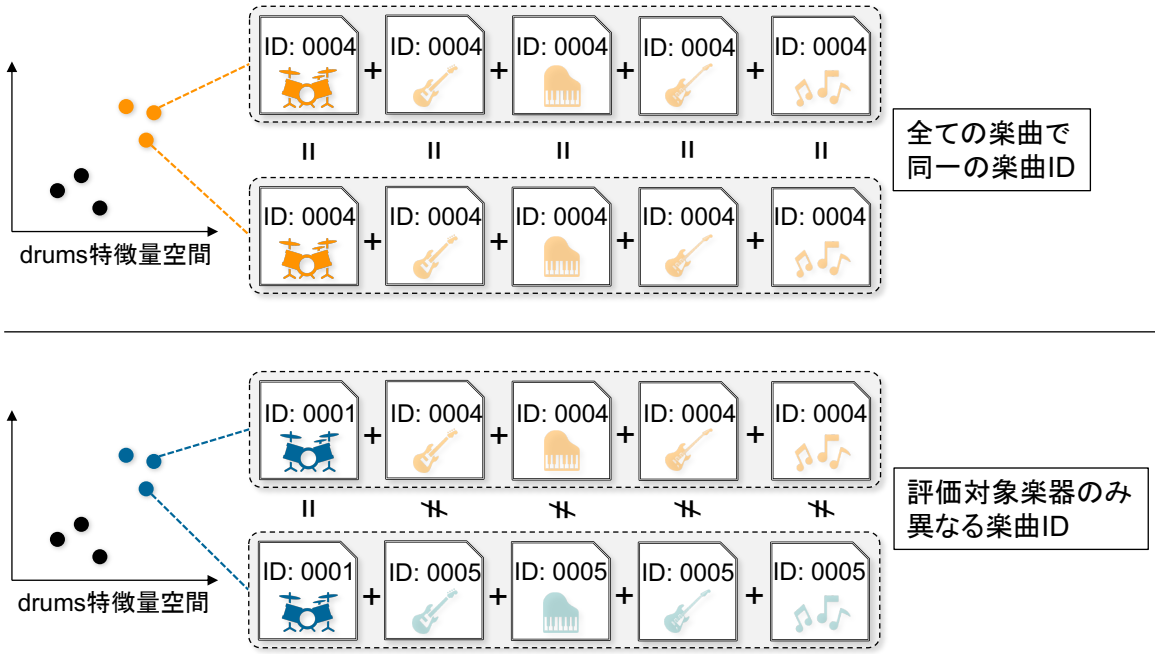


図 4.3: 通常テスト楽曲と擬似テスト楽曲の概要.

ての楽器で同一であった．そのため，MES-Normal では各楽器音類似度特徴量の分離性能を評価することが本質的に困難であった．分離性能を調査するために，MES-Pseudo では擬似テスト楽曲を用いて評価した．MES-Pseudo では，図 4.3 の下部に示すように，正解ラベルが評価対象楽器と他の楽器で異なる．例えば，評価対象楽器（すなわち，drums）のラベルは他の楽器のラベルとは異なる．

テストに使用する擬似楽曲は以下の手順で生成された：

1. テストデータセットから対象楽器ステム用に 10 楽曲を選択,
2. これらの 10 楽曲のそれぞれについて，自身の楽曲を除いたテストデータセットからさらに 3 楽曲を選択し，非対象楽器ステム用として使用,
3. 10 楽曲の対象楽曲と対応する 3 楽曲の非対象楽曲を混合し，合計 30 曲の擬似テスト楽曲を生成,
4. 各擬似テスト楽曲ごとに，10 個の楽曲セグメントを生成，合計 400 セグメントを

用意.

MES-Pseudo の全テストデータは，これら 30 個の擬似楽曲と対象楽曲として使用された 10 楽曲の通常楽曲を合わせた，合計 40 楽曲で構成される．テストにおいては，各テストセグメントと同一楽曲から抽出された全てのセグメントを除外することで，非対象楽器に着目した楽曲 ID 推定を防止した．すなわち，30 個の擬似楽曲のいずれかのセグメントをテストセグメントとして使用する場合，2 個の擬似楽曲と 1 個の通常楽曲内のセグメントのみが正解楽曲 ID ラベルを持つ．一方，10 個の通常楽曲のいずれかのセグメントをテストセグメントとして使用する場合，3 個の擬似楽曲内のセグメントが正解楽曲 ID ラベルを持つ.

擬似テスト楽曲に対する評価値の可視化

下位楽器区分は 129 種類の楽器を含むため，全楽器の評価値を確認することは困難である．また，入力テキストで指定された楽器と擬似テスト楽曲の評価対象楽器が異なる場合のモデルの挙動についても評価する必要がある．そこで，本実験では，入力テキストの指定楽器と擬似テスト楽曲の評価対象楽器を総当たりにして精度を計算し可視化する．総当たりに計算した精度は，テキスト楽器-評価対象楽器ペアで混合行列化されて可視化される.

4.4.5　評価結果

上位楽器区分に属する楽器に対する評価結果

表 4.1 に Slakh-Core および Slakh-Super における通常テスト楽曲に対する楽曲 ID 推定評価の結果を，表 4.2 に擬似テスト楽曲に対する楽曲 ID 推定評価の結果を示す.

まず Slakh-Core に対する評価結果に着目し，従来手法との性能比較を行う．評価結

表 4.1: Slakh-Core および Slakh-Super に対する評価結果．MES-Normal の結果を示す．**太字**は最も良い評価値を示す．

Method	drums	bass	piano	guitar	brass	chromatic percussion	organ	pipe	Reed	Strings	Strings (continued)	Synth lead	Synth pad	Mean
	Slakh-Core													
Direct [41]	89.33	71.09	79.74	81.75	–	–	–	–	–	–	–	–	–	80.48
Direct-Reconst [41]	**91.14**	**81.30**	**84.76**	**85.17**	–	–	–	–	–	–	–	–	–	**85.59**
proposed method	**82.99**	**49.96**	**70.39**	**71.09**	–	–	–	–	–	–	–	–	–	68.60
– pre-training	70.10	31.55	38.34	45.96	–	–	–	–	–	–	–	–	–	46.49
– Decoder	63.43	10.67	10.63	9.39	–	–	–	–	–	–	–	–	–	23.53
	Slakh-Super													
proposed method	**88.98**	56.36	**80.17**	**80.55**	**70.66**	**75.55**	**74.93**	**62.25**	**70.69**	**66.88**	**72.98**	**81.75**	**81.45**	**74.09**
– pre-training	88.88	**65.12**	63.07	61.99	53.73	68.24	63.69	49.34	60.31	53.34	58.88	72.93	70.05	63.81
– Decoder	17.68	15.12	22.58	17.73	20.98	26.35	15.18	10.37	21.26	23.65	25.25	24.63	19.24	20.00

果より，提案手法は通常テスト楽曲と擬似テスト楽曲の双方において提案手法は *Direct* 手法に全ての楽器において評価値が劣っている．これは提案手法が類似度表現性能および各楽器音特徴量分離性能の双方において従来手法よりも性能が劣っていることを示す．*Direct* アプローチは出力特徴量の特定次元が特定の楽器音類似度特徴量として扱われるため，ネットワークに特定の楽器専用に学習されたパラメータが存在する．しかし提案手法はネットワーク全体を全楽器が共有しているため，特定の楽器専用のパラメータは存在しない．特定楽器専用のパラメータを用いていないことが提案手法の性能の低さの一因であると考えられる．しかしながら，特定楽器専用のパラメータの存在は学習対象の楽器数の増加に伴う計算量およびパラメータ数増加の原因となりうるため，多くの楽器を扱うにはボトルネックになりうる．提案手法は特定楽器専用のパラメータを用いていないため，従来手法より性能では劣っているが，それにより多くの楽器を扱う上でのボトルネックを取り除くことに繋がっている．

さらに，提案手法は，テキスト表現ベースで類似度特徴量抽出器のみのモデル（5 行目）と比較したとき，楽器音再構成器を用いた音源分離との同時学習および事前学習によって，通常テスト楽曲および擬似テスト楽曲の双方において性能を大きく向上さ

表 4.2: Slakh-Core および Slakh-Super に対する評価結果．MES-Pseudo の結果を示す．**太字**は最も良い評価値を示す．

Method	drums	bass	piano	guitar	brass	chromatic percussion	organ	pipe	Reed	Strings	Strings (continued)	Synth lead	Synth pad	Mean
	Slakh-Core													
Direct [41]	97.93	68.22	69.22	63.24	–	–	–	–	–	–	–	–	–	74.65
Direct-Reconst [41]	**98.25**	**77.74**	**79.20**	**82.47**	–	–	–	–	–	–	–	–	–	**84.42**
proposed method	**96.62**	**67.44**	**72.63**	**65.16**	–	–	–	–	–	–	–	–	–	**75.46**
– pre-training	95.41	46.29	32.24	32.69	–	–	–	–	–	–	–	–	–	51.66
– Decoder	91.48	9.75	9.25	19.00	–	–	–	–	–	–	–	–	–	32.37
	Slakh-Super													
proposed method	97.25	**58.25**	**53.50**	**77.00**	**77.50**	88.00	**85.50**	**49.25**	**49.50**	**31.75**	**75.25**	**72.75**	**40.75**	**65.87**
– pre-training	**99.50**	15.75	22.00	55.25	54.50	**88.50**	75.00	19.00	31.25	18.25	42.25	54.50	29.75	46.58
– Decoder	11.00	8.25	10.75	11.00	6.00	33.25	9.25	17.75	8.00	11.00	14.50	18.00	4.50	12.56

せている．これは，音源分離で学習される楽器音源のセマンティックな情報が類似度特徴量抽出に有益であることを示唆する．

次に，Slakh-Core に対する評価結果と Slakh-Super に対する評価結果を比較する．まず Slakh-Super における Slakh-Core に該当する部分（drums, bass, piano, guitar）に着目することで，Slakh-Core での性能と Slakh-Super での性能を比較する．評価結果より，Slakh-Super での Slakh-Core に該当する drum, bass, piano, guitar の性能が，通常テスト楽曲に対しては評価値が上昇する（表 4.1）のに対し，擬似テスト楽曲においては，drums と guitar は上昇しているのが bass と piano では減少している（表 4.2）ことがわかる．通常テスト楽曲において評価値が上昇していることから，複数の楽器を同時に学習することがモデルの楽曲の多様な特徴量を捉える能力を養うことにつながることが示唆される．さらに擬似楽曲においては性能の上下に楽器差があることから，同時に学習する楽器によって性能の上下が発生することが示唆される．

最後に，Slakh-Super に対する評価結果について述べる．Slakh-Super においても，Slakh-Core と同様，テキスト表現ベースで類似度特徴量抽出器のみのモデルと比較して，音源分離との同時学習および事前学習によって通常テスト楽曲および擬似テスト楽

表 4.3: 下位楽器区分に対する評価結果．各楽器に対する評価結果の平均値のみを示す．**太字**は最も良い評価値を示す．

Method	通常テスト楽曲		擬似テスト楽曲	
	seen inst. (# of inst = 40)	unseen inst. (# of inst = 21)	seen inst. (# of inst = 37)	unseen inst. (# of inst = 16)
	Slakh-Sub			
proposed method	**76.70**	**79.69**	**48.65**	**21.25**
− pre-training	70.72	68.32	20.97	11.32
− decoder	29.12	31.33	8.85	7.47

曲の双方で性能が大きく向上している．特に, 楽器音再構成器の有無では, MES-Pseudo の全楽器音の平均精度で 12.56%から 65.87%と大きく性能が向上しており，これは，音源分離によってモデルに明示的に楽曲音源における目的楽器の特徴を掴むことができていることを示唆する．

下位楽器区分に対する評価結果

表 4.3 に，下位楽器区分に対する評価結果を示す．表 4.3 より，Slakh-Core や Slakh-Super の楽器数（4，13）と比較すると楽器数が格段と増加しているが，提案手法は，テキスト表現ベースで楽器音再構成器なし類似度特徴量抽出器のみのモデル（3 行目）と比較すると，MES-Normal，MES-Pseudo 双方で上回る性能を獲得している．このことから，提案手法における音源分離タスクとの同時学習および事前学習が，シンプルな特徴量抽出のみというベースラインに対して効果的な学習を促すことを示唆する．

さらに，提案手法は学習されていない条件の楽器に対しても類似度表現を可能とする．具体的には，通常テスト楽曲に対しては学習された楽器と同等の性能を，擬似テスト楽曲に対しては学習された楽器と比較すると性能は劣るものの，ある程度の性能

を発揮することができている．これは，テキスト特徴量抽出器が未知の入力テキスト，入力楽器に対して頑健性をもち，未知の楽器であってもその楽器情報が類似度特徴量抽出器に伝達されるためである．

提案手法は，従来手法と比較して，パラメータ数を増加させることなくより多くの楽器を学習させることができるだけでなく，未知の楽器に対する類似度表現を行うことができる．

4.4.6　議論

擬似テスト楽曲に対する評価値の可視化

図 4.5，図 4.6，図 4.7 に類似度特徴量抽出器のみのモデル，楽器音再構成器ありのモデル，楽器音再構成器 + 事前学習ありモデルの擬似テスト楽曲に対する評価値の可視化結果を示す．

結果より，まず，類似度特徴量抽出器のみのモデルは結果に縦線の発火が見られる．縦線の発火は入力テキストで指定する楽器が変わっても評価値が変わらないことを意味する．評価値が変わらない，すなわち着目されている楽器が固定であることを示唆している．つまり，類似度特徴量抽出器のみのモデルは入力テキストによる楽器指定が不十分な性能であることが示唆される．対して，提案手法の楽器音再構成器 + 事前学習ありモデルは対角成分の発火が見られる．対角成分の発火は入力テキストで指定される楽器と擬似テスト楽曲の評価対象楽器が一致した時のみ評価値が高く，一致していない場合には評価値が低いことを示唆する．すなわち，提案手法は，類似度特徴量抽出器のみのモデルより，入力テキストによる楽器指定により対象楽器のみの類似度特徴量を抽出する能力が高いことを示唆する．

表 4.4: Slakh-Super で学習されたモデルによる Slakh-Sub に対する評価結果．擬似テスト楽曲に対する楽曲 ID 推定の評価値を示す．**太字**は最も良い評価値を示す．

Method	擬似テスト楽曲			
	seen inst. (# of inst = 37)	unseen inst. (# of inst = 16)	seen inst. (# of inst = 37)	unseen inst. (# of inst = 16)
	Slakh-Super で学習		**Slakh-Sub で学習**	
proposed method	**23.66**	**16.75**	**48.65**	**21.25**
− pre-training	15.95	11.55	20.97	11.32
− decoder	8.27	7.25	8.85	7.47

Slakh-Super で学習されたモデルを Slakh-Sub で評価

表 4.4 に Slakh-Super で学習したモデルでの Slakh-Sub に対する評価値を示す．Slakh-Super で学習されたモデルで Slakh-Sub のデータの推論をする場合は，Slakh-Sub の楽器名をテキスト表現として用いた．評価値は擬似テスト楽曲に対する楽曲 ID 推定の結果である．“unseen inst.” は Slakh-Sub で学習した場合に学習対象に含まれていなかった楽器を表す．

評価結果より，Slakh-Sub で学習されたモデルでは，全てのモデルが．“seen inst.” において Slakh-Super で学習されたモデルを上回っていることがわかる．Slakh-Super で学習されたモデルは Slakh-Sub のデータを含んで学習を行っているため Slakh-Sub における音響的特徴を取り込んでいる可能性がある．実際，提案手法モデルを Slakh-Super で学習した場合，Slakh-Sub においてもある程度性能が出ていることがわかる．しかしながら，Slakh-Sub で学習されたモデルに性能では劣っていることから，Slakh-Super での上位楽器での学習では Slakh-Sub での下位楽器間の類似度特徴を十分学習できないことが示唆される．この結果より，Slakh-Sub のデータによって学習することの効果が示唆される．さらに，この結果は，Slakh-Sub のような学習対象楽器の多いデータに

対して計算量やリソースを増やすことなく対応できるテキスト表現による楽器指定手法である提案手法の優位性を協調する結果であると言える．

Slakh-Sub の楽器の類似度特徴量空間の可視化

擬似テスト楽曲を入力とし，出力として得た類似度特徴量を可視化した結果を図 4.9，図 4.10，図 4.11 に示す．評価結果より，類似度特徴量抽出器のみのモデルの特徴量空間は同一色（つまり対象楽器音が同一楽曲セグメント）の特徴量だけでなく異なる色（つまり対象楽器音が非同一楽曲セグメント）の特徴量も含まれたクラスタも形成されていることがわかるが，提案手法は，異なる色の特徴量同士は離散し，同一色のみが集まったクラスタが形成されていることがわかる．このことより，提案手法は楽器音再構成器を用いて音源分離との同時学習や事前学習を導入することで，類似度特徴量抽出器のみのモデルより有効な学習を行えていることが示唆される．加えて，類似度特徴量抽出器のみのモデルと比較して，楽器音再構成器ありのモデル（事前学習なし）が異なる色の点を拡散させたより理想的な特徴量空間を形成していることがわかる．このことから，楽器音再構成器による音源分離タスクが楽器音類似度特徴量分離性能を大きく改善させることがわかる．

Slakh-Sub の全楽器に対する類似度特徴量の可視化結果

図 4.12 に，提案手法による Slakh-Sub の全楽器の類似度特徴量を可視化結果を示す．結果より，楽器ごとに特徴量がクラスタを形成していることがわかる．提案手法の学習は，同一楽器音に対して楽曲内類似度に基づいたトリプレット損失による学習でしか特徴量抽出タスクに対しては学習していないため，異なる楽器間を特徴量空間上で離散させる学習を明示的には行っていない．モデルはテキスト特徴量表現に基づいて出力特徴量を条件付けており，テキスト特徴量ごとに異なる部分に類似度特徴量を埋め込んでいることがわかる．さらに，結果より，同一色（同一の Slakh-Super の楽器

に属することを意味する）の楽器が特徴量区間である程度集まっていることがわかる．このことから，特徴量空間が Slakh-Sub が持つ階層性を暗に学習していることが示唆される．

4.5 本章のまとめ

本章では，従来の InMSRL 手法における計算量の増加および未知楽器への非対応という課題に対処するため，テキスト表現による楽器指定手法について述べた．4.2 節では，提案手法のネットワーク構造について述べた．4.3 節では，提案手法の学習手法について述べた．4.4 節では，提案手法の実験的評価について述べた．

図 4.4: 擬似テスト楽曲に対する評価値の可視化結果．縦軸は入力テキストに用いた楽器を，横軸は擬似テスト楽曲の評価対象楽器を表す．**太字**は最も良い評価値を示す．

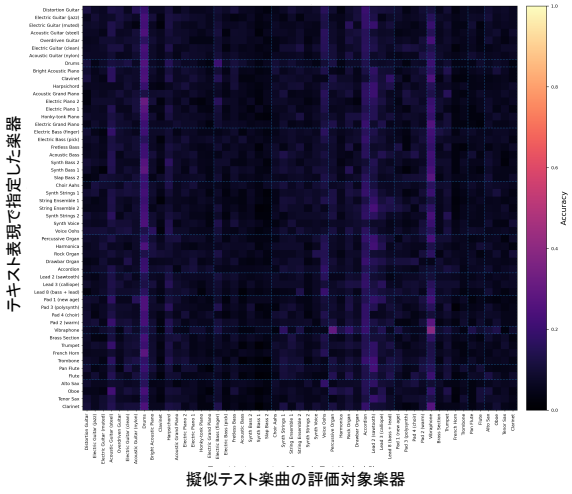


図 4.5: 類似度特徴量抽出器のみのモデルの評価値

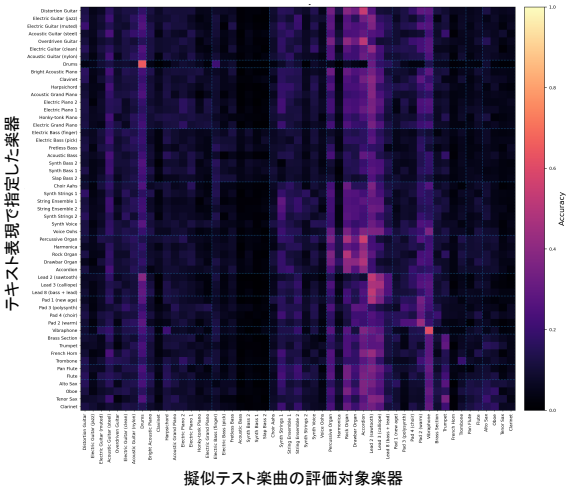


図 4.6: 楽器音再構成器ありのモデルの評価値

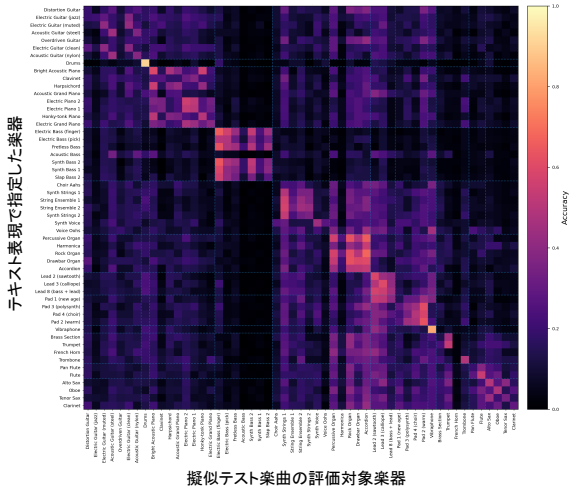


図 4.7: 楽器音再構成器あり＋事前学習あり（提案手法）モデルの評価値

図 4.8: 擬似テスト楽曲を入力とし，出力として得た類似度特徴量を可視化した結果．評価対象楽器には，Slakh-Sub から *“oboe”* を選択した．t-SNE [72] を用いて可視化した．同一色は評価対象楽器が同一楽曲のセグメントから抽出されている特徴量であることを示す．また，同一色で非同一形状の点同士は評価対象楽器は同一楽曲セグメントだが非評価対象楽器は非同一楽曲セグメントであることを表す．

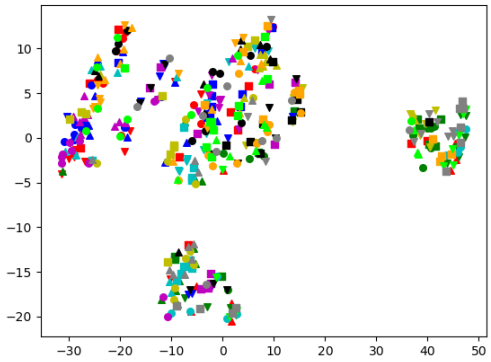


図 4.9: 類似度特徴量抽出器のみのモデル

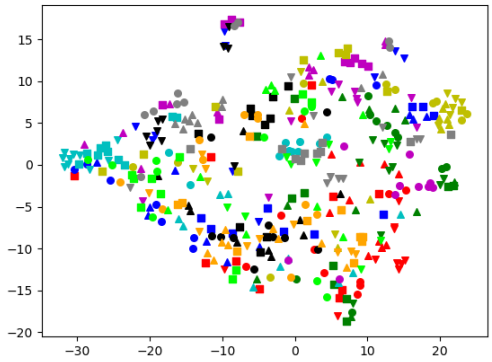


図 4.10: 楽器音再構成器ありのモデル

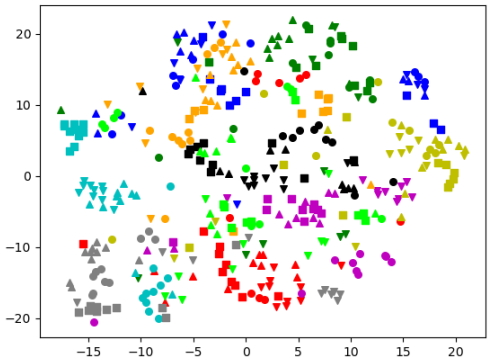


図 4.11: 楽器音再構成器＋事前学習あり（提案手法）のモデル

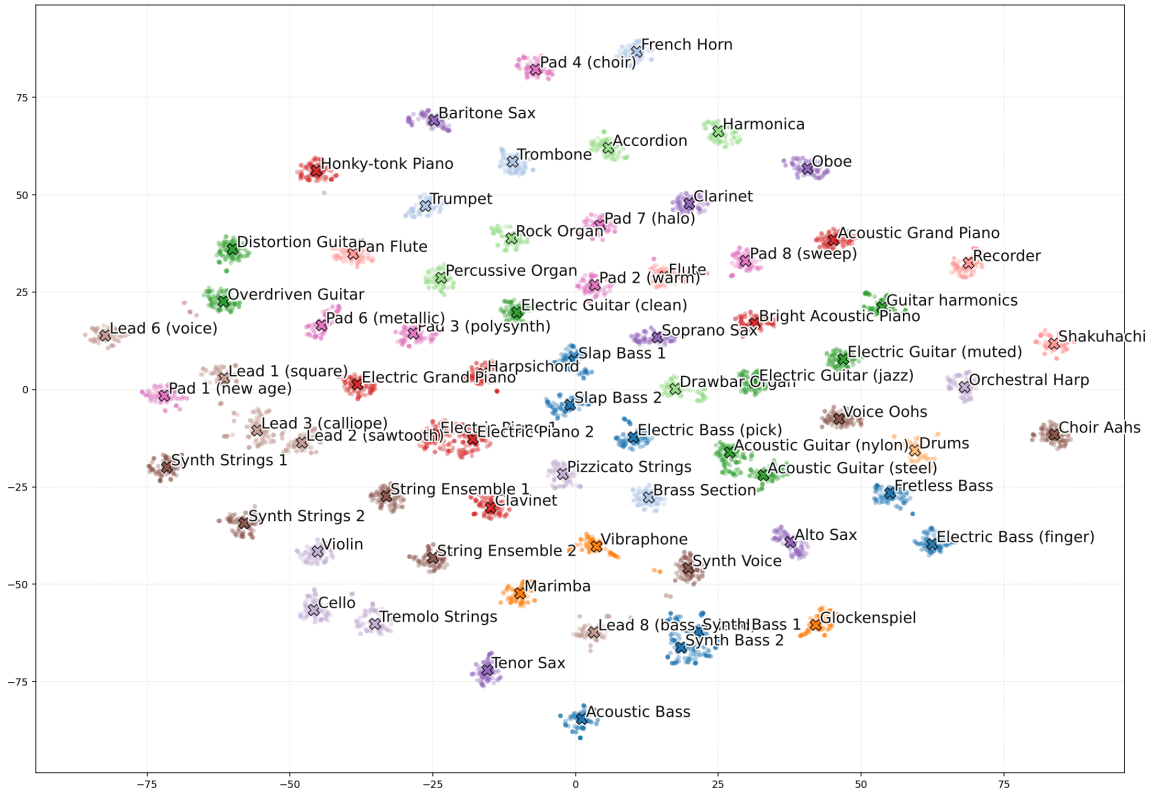


図 4.12: 提案手法による Slakh-Sub の全楽器に対する類似度特徴量の可視化結果．通常テスト楽曲のセグメントを各楽器音ごとにランダムに 100 セグメント選択し，提案手法で特徴量抽出した．同一色は同一の slakh-Super の楽器に属する Slakh-Sub 楽器であることを表す．

第5章　結論

5.1　本論文のまとめ

本論文では，個別楽器音に基づく楽曲間類似度表現学習（Instrument-Wise Music Similarity Representation Learning; InMSRL）における人間の知覚，知見，知識の導入について研究を行った．

第 2 章では，InMSRL の従来手法および関連研究について述べた．InMSRL の従来手法として，クリーンな個別楽器ステムを入力とする *Clean* 手法，音源分離モデルと類似度特徴量抽出器を逐次的に用いる *Cascade* 手法，楽曲から直接楽器ごとの類似度表現を学習する *Direct* 手法について述べた．これらの手法は「同一楽曲内のセグメント同士は異なる楽曲間のセグメント同士より類似している」という楽曲内類似度に基づく自己教師あり学習を導入しているが，楽曲間類似度または知覚的類似度を獲得できる確約はないことについて触れた．従来手法の評価手法である ABX テストについて述べ，実際に楽曲内類似度に基づく学習では人間の知覚的類似度を十分に捉えられないことが先行研究により指摘されていることを述べた．さらに，関連研究として，音源分離で広く用いられている U-Net，知覚的類似度ラベルを用いた学習手法，テキスト表現による特徴量抽出手法について述べた．

第 3 章では，InMSRL における知覚的類似度の表現不足という課題に対処するための学習戦略について述べた．提案手法として，信号処理に基づく楽曲間類似度表現（Signal-Processing-based Music Similarity Representation; SP-MSR）を従来手法の自己教師あり学習の類似度基準として導入し，その後，人手で付与された少量の知覚的類似度ラベ

ルを用いた fine-tuning 手法（Perception-Aware Fine-Tuning; PAFT）を適用する二段階の学習戦略について述べた．SP-MSR として，大域的な音色類似度を捉える Global Temporal Averaging（GlobalTA），局所的な音色類似性を捉える Localized Timbral Similarity（LocalTS），リズム特徴を捉える Fluctuation Patterns（FPs）の 3 つの手法を導入した．これらは人間の音楽的知見に基づいて設計されており，楽曲内類似度だけでは表現できない複雑な類似度特徴をモデルに学習させることを可能にする．実験的評価では，ABX テストに基づく知覚的類似度一致率を用いて評価を行った．実験の結果，SP-MSR 手法単体で従来の機械学習モデルより高い InMSRL 性能を示すことが確認された．さらに，SP-MSR に基づく事前学習の後に PAFT を適用することで，事前学習なしの PAFT のみの学習や，楽曲内類似度のみに基づく事前学習より高い性能を達成した．この結果は，クリーンな楽器音を入力とする *Clean* 手法と，楽曲音源自体を入力とする *Cascade* 手法の双方で確認され，理想的な状況と実応用的な状況の両方において提案手法の有効性が示された．また，複数の SP-MSR 手法を統合する手法は，単一の類似度基準のみを用いる手法より高い性能を示す傾向があり，異なる基準に基づく複数の類似表現を組み合わせることの有効性が示された．

第 4 章では，従来の InMSRL 手法における計算量の増加および未知楽器への非対応という課題に対処するため，テキスト表現による楽器指定手法について述べた．提案手法として，テキストと楽曲間の大規模対照学習で得られるテキスト特徴量を用いて，類似度特徴量抽出器を条件付けする手法について述べた．具体的には，MuQ-MuLan の事前学習済みテキストエンコーダから得られるテキスト特徴量を FiLM（Feature-wise Linear Modulation）により，U-Net 型のエンコーダ・デコーダ構造を持つ特徴量抽出器に組み込む手法について述べた．これにより，テキスト単位での楽器割り当てが可能となり，楽器数増加によるリソース増加を抑制できる．また，大規模な対照学習により獲得された頑健なテキスト表現により，学習されていない楽器にも対応可能となる．実験的評価では，Slakh データセットを用いて，4 種類の楽器（Slakh-Core），16 種類の上

位楽器区分（Slakh-Super），129 種類の下位楽器区分（Slakh-Sub）の 3 つの条件で評価を行った．評価指標として，通常テスト楽曲における楽曲 ID 推定精度（MES-Normal）と擬似テスト楽曲における楽曲 ID 推定精度（MES-Pseudo）を用いた．実験の結果，提案手法は従来の *Direct* 手法やエンコーダのみのモデルと比較して，特に MES-Pseudo において高い性能を示し，個別楽器音に基づく類似度特徴量の分離性能が向上することが確認された．また，学習時に含まれていない楽器に対しても一定の性能を発揮することが示され，未知楽器への対応可能性が示された．

5.2 今後の課題

今後の展望としては大きく 3 つ存在する．

一つ目は生音楽器の楽曲を用いることである．本研究では，Slakh データセットを用いて実験を行ったが，このデータセットは MIDI から生成された楽器音で構成されている．実際の音楽推薦・検索システムでは，生音楽器の楽曲が多く含まれる．電子音源と生音楽器では音色特性が大きく異なるため，生音楽器を含むデータセットでの評価が必要である．本研究で用いた音源分離モデルやテキスト特徴量抽出器が生音楽器に対してどの程度有効であるかを検証することが今後の課題である．しかしながら，生音楽曲のクリーンなステム音源は一般的には公開されていない場合が多い．そのため，本実験で用いた Slakh データセットのような，学習および評価に十分な量のステム音源を入手できるとは限らない．そのため，少量のデータのみの使用に制限された状況でのより効率的な学習手法の提案や，MIDI ベースの音源を用いて学習されたモデルの生音音源データへのドメイン適応手法の導入が求められる．

二つ目は，より複雑な信号処理手法を学習に導入することである．本研究では，GlobalTA，LocalTS，FPs の 3 つの SP-MSR 手法を導入したが，人間の音楽的知見に基づく信号処理手法は他にも多数存在する．例えば，和声進行やメロディの輪郭といった

高次の音楽的構造を捉える手法や，音響心理学に基づく知覚特性を反映した特徴量抽出手法などが考えられる．複数のSP-MSR手法を統合することの有効性が本研究で示されたことから，より多様なSP-MSR手法を探索し，それらを効果的に組み合わせる手法の開発が期待される．さらに，深層学習モデルとSP-MSRを融合した新たなアーキテクチャの設計も興味深い研究方向である．

三つ目は，テキスト表現による楽器指定手法のゼロショット性能の改善と，複雑なテキスト表現の評価および適応である．本研究では，事前学習済みテキストエンコーダを用いたが，学習時に含まれていない楽器に対する性能は学習済み楽器と比較して限定的であった．未知楽器への対応性能を向上させるため，より多様な楽器カテゴリの導入など必要である．さらに，楽器名だけでなく，演奏スタイルや音楽ジャンルといったより複雑なテキスト記述を条件として用いることで，より細かい粒度での類似度表現が可能になると考えられる．楽器音だけでなく，音色や雰囲気といったより抽象的なテキスト表現に対応した楽曲間類似度特徴量抽出を可能にすることで，より高次元な検索および推薦を可能にすることにつながる．

謝辞

本研究を進めるにあたり，指導教員の 戸田智基 教授には，終始熱心なご指導ならびに的確な助言を賜りました．研究の方針から対外発表における原稿・発表資料の添削に至るまで丁寧にお付き合いいただき，円滑な研究生活を送ることができました．心より感謝の意を表します．名古屋大学大学院情報学研究科の ホワンウェンチン 助教には，日頃から論文の書き方や研究の進め方について非常に丁寧なアドバイスをいただきました．心より感謝申し上げます．また，名古屋大学大学院情報学研究科知能システム学専攻戸田研究室の 橋爪優果 修士には，研究内容や原稿執筆について的確な助言とご協力をいただきました．心より感謝の意を表します．セミナーや中間発表などで重要な助言や質問をくださった，名古屋大学大学院情報学研究科知能システム学専攻武田研究室の 藤井慶輔 准教授をはじめとする先生方にも，心より感謝いたします．名古屋大学大学院情報学研究科知能システム学専攻戸田研究室ならびに武田研究室の皆様には，セミナー等で研究に関する様々な助言をいただき，実験にもご協力いただきました．また，研究室生活においても多くのサポートをしていただき，大変お世話になりました．深く感謝申し上げます．最後に，6 年間の学生生活を支えてくださった家族と友人に，心より感謝申し上げます

参考文献

[1] IFPI. Ifpi: Amidst highly competitive market, global recorded music revenues grew 4.8% in 2024, 2025. https://www.ifpi.org/ifpi-amidst-highly-competitive-market-global-recorded-music-\\revenues-grew-4-8-in-2024/.

[2] Spotify. Spotify reports third quarter 2025 earnings, 2025. https://newsroom.spotify.com/2025-11-04/spotify-q3-2025-earnings/.

[3] Luminate. Music year-end report 2024, 2025. https://view.ceros.com/luminate-data/music-year-end-report-2024.

[4] Y. Song, S. Dixon, and M. Pearce. A survey of music recommendation systems and future perspectives. In *Proc. CMMR*, pp. 395–410, 2012.

[5] P. Resnick and H. Varian. Recommender systems. *Communications of the ACM*, Vol. 40, No. 3, pp. 56–58, 1997.

[6] G. Tzanetakis and P. Cook. Musical genre classification of audio signals. *IEEE Trans. Speech & Audio Processing*, Vol. 10, No. 5, pp. 293–302, 2002.

[7] A. Holzapfel and Y. Stylianou. Musical genre classification using nonnegative matrix factorization-based features. *IEEE Trans. Audio, Speech, & Language Processing*, Vol. 16, No. 2, pp. 424–434, 2008.

[8] T. Lidy and A. Rauber. Evaluation of feature extractors and psycho-acoustic transformations for music genre classification. In *Proc. ISMIR*, pp. 34–41, 2005.

[9] J. T. Foote. Content-based retrieval of music and audio. In *Proc. SPIE Multimedia Storage and Archiving Systems II*, pp. 138–147, 1997.

[10] E. Pampalk. Computational models of music similarity and their application in music information retrieval. *PhD thesis, Vienna University of Tech*, 2006. 165 pages.

[11] T. Pohle, D. Schnitzer, M. Schedl, P. Knees, and G. Widmer. On rhythm and general music similarity. In *Proc. ISMIR*, pp. 525–530, 2006.

[12] B. Logan and A. Salomon. A music similarity function based on signal analysis. In *Proc. ICME*, pp. 22–25, 2001.

[13] Z. Liu and Q. Huang. Content-based indexing and retrieval-by-example in audio. In *Proc. ICME*, pp. 877–880, 2000.

[14] J.-J. Aucouturier and F. Pachet. Music similarity measures: What's the use? In *Proc. ISMIR*, pp. 157–163, 2002.

[15] A. van den Oord, S. Dieleman, and B. Schrauwen. Deep content-based music recommendation. In *Proc. NeurIPS*, pp. 2643–2651, 2013.

[16] K. Choi, G. Fazekas, and M. Sandler. Automatic tagging using deep convolutional neural networks. In *Proc. ISMIR*, pp. 805–811, 2016.

[17] V. Lostanlen and C.-E. Cella. Deep convolutional networks on the pitch spiral for music instrument recognition. In *Proc. ISMIR*, pp. 612–618, 2016.

[18] A. Elbir and N. Aydin. Music genre classification and music recommendation by using deep learning. *Electronics Letters*, pp. 627–629, 2020.

[19] J. Choi, J. Lee, J. Park, and J. Nam. Learning to rank music tracks using triplet loss. In *Proc. ISMIR*, pp. 67–74, 2019.

[20] J. Pons and X. Serra. musicnn: Pre-trained convolutional neural networks for music audio tagging. *arXiv preprint arXiv:1909.06654*, 2019. 2 pages.

[21] Y. Li, R. Yuan, G. Zhang, Y. Ma, X. Chen, H. Yin, C. Xiao, C. Lin, A. Ragni, E. Benetos, N. Gyenge, R. Dannenberg, R. Liu, W. Chen, G. Xia, Y. Shi, W. Huang, Z. Wang, Y. Guo, and J. Fu. Mert: Acoustic music understanding model with large-scale self-supervised training. In *Proc. ICLR*, pp. 1–23, 2024.

[22] Y. Li, R. Yuan, G. Zhang, Y. Ma, C. Lin, X. Chen, A. Ragni, H. Yin, Z. Hu, H. He, E. Benetos, N. Gyenge, R. Liu, and J. Fu. Map-music2vec: A simple and effective baseline for self-supervised music audio representation learning. *In Late-Breaking Demo Session of ISMIR*, 2022. 3 pages.

[23] M. C. McCallum, F. Korzeniowski, S. Oramas, F. Gouyon, and A. F. Ehmann. Supervised and unsupervised learning of audio representations for music understanding. In *Proc. ISMIR*, pp. 256–263, 2022.

[24] J. Park, J. Lee, J. Park, J.-W. Ha, and J. Nam. Representation learning of music using artist labels. In *Proc. ISMIR*, pp. 717–724, 2018.

[25] J. Choi, J. Lee, J. Park, and J. Nam. Zero-shot learning for audio-based music classification and tagging. In *Proc. ISMIR*, pp. 67–74, 2019.

[26] A. Frome, G. S. Corrado, J. Shlens, S. Bengio, J. Dean, M. Ranzato, and T. Mikolov. Devise: A deep visual-semantic embedding model. In *Proc. NeurIPS*, pp. 2121–2129, 2013.

[27] F. Schroff, D. Kalenichenko, and J. Philbin. Facenet: A unified embedding for face recognition and clustering. In *Proc. CVPR*, pp. 815–823, 2015.

[28] M. C. McCallum. Unsupervised learning of deep features for music segmentation. In *Proc. ICASSP*, pp. 346–350, 2019.

[29] J. Spijkervet and J. A. Burgoyne. Contrastive learning of musical representations. In *Proc. ISMIR*, pp. 673–681, 2021.

[30] M. C. McCallum, M. E. P. Davies, F. Henkel, J. Kim, and S. E. Sandberg. On the effect of data-augmentation on local embedding properties in the contrastive learning of music audio representations. In *Proc. ICASSP*, pp. 671–675, 2024.

[31] R. Yuan, Y. Ma, Y. Li, G. Zhang, X. Chen, H. Yin, L. Zhuo, Y. Liu, J. Huang, Z. Tian, B. Deng, N. Wang, C. Lin, E. Benetos, A. Ragni, N. Gyenge, R. Dannenberg, W. Chen, G. Xia, W. Xue, S. Liu, S. Wang, R. Liu, Y. Guo, and J. Fu. Marble: Music audio representation benchmark for universal evaluation. In *Proc. NeurIPS*, pp. 39626–39647, 2023.

[32] W.-N. Hsu, B. Bolte, Y.-H. H. Tsai, K. Lakhotia, R. Salakhutdinov, and A. Mohamed. Hubert: Self-supervised speech representation learning by masked prediction of hidden units. *IEEE/ACM TASLP*, pp. 3451–3460, 2021.

[33] Y. Ma, R. Yuan, Y. Li, G. Zhang, X. Chen, H. Yin, C. Lin, E. Benetos, A. Ragni, N. Gyenge, R. Liu, G. Xia, R. Dannenberg, Y. Guo, and J. Fu. On the effectiveness of speech self-supervised learning for music. In *Proc. ISMIR*, pp. 457–465, 2023.

[34] A. Défossez, J. Copet, G. Synnaeve, and Y. Adi. High fidelity neural audio compression. *arXiv preprint arXiv:2210.13438*, 2022. 19 pages.

[35] A. Baevski, W.-N. Hsu, Q. Xu, A. Babu, J. Gu, and M. Auli. data2vec: A general framework for self-supervised learning in speech, vision and language. In *Proc. ICML*, pp. 1298–1312, 2022.

[36] P. Dhariwal, H. Jun, C. Payne, J. W. Kim, A. Radford, and I. Sutskever. Jukebox: A generative model for music. *arXiv preprint arXiv:2005.00341,*, 2020. 20 pages.

[37] R. Castellon, C. Donahue, and P. Liang. Codified audio language modeling learns useful representations for music information retrieval. In *Proc. ISMIR*, pp. 88–96, 2021.

[38] Q. Huang, A. Jansen, J. Lee, R. Ganti, J. Y. Li, and D. P. W. Ellis. Mulan: A joint embedding of music audio and natural language. In *Proc. ISMIR*, pp. 559–566, 2022.

[39] Y. Hashizume, L. Li, and T. Toda. Music similarity calculation of individual instrumental sounds using metric learning. In *Proc. APSIPA ASC*, pp. 33–38, 2022.

[40] Y. Hashizume, L. Li, A. Miyashita, and T. Toda. Learning separated representations for instrument-based music similarity. *APSIPA Transactions on Signal and Information Processing*, Vol. 14, No. 1, pp. 1–32, 2025.

[41] T. Imamura, Y. Hashizume, and T. Toda. Multi-task learning approaches for music similarity representation learning based on individual instrument sounds. In *Proc. APSIPA ASC*, 2024. 6 pages.

[42] R. Hennequin, A. Khlif, F. Voituret, and M. Moussallam. Spleeter: A fast and state-of-the art music source separation tool with pre-trained models. *The Journal of Open Source Software*, Vol. 5, No. 50, p. 2154, 2019.

[43] A. Veit, S. Belongie, and T. Karaletsos. Conditional similarity networks. In *Proc. CVPR*, pp. 1781–1789, 2017.

[44] J. Lee, N. J. Bryan, J. Salamon, Z. Jin, and J. Nam. Disentangled multidimensional metric learning for music similarity. In *Proc. ICASSP*, pp. 6–10, 2020.

[45] Y. Hashizume and T. Toda. Investigation of perceptual music similarity focusing on each instrumental part. In *Proc. ICASSP*, 2025. 5 pages.

[46] E. Hoffer and N. Ailon. Deep metric learning using triplet network. In *Proc. SIMBAD*, pp. 84–92, 2015.

[47] O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. In *Proc. MICCAI*, pp. 234–241, 2015.

[48] A. Jansson, E. J. Humphrey, N. Montecchio, R. M. Bittner, A. Kumar, and T. Weyde. Singing voice separation with deep u-net convolutional networks. In *Proc. ISMIR*, pp. 23–27, 2017.

[49] S. Huang, N. Hou, P. Xiong, F. Bao, and J. Zhang. Contrastive learning-based non-intrusive speech intelligibility prediction. In *Proc. ICASSP*, pp. 1–5, 2023.

[50] W. Zhang, W. Zou, and X. Li. Self-supervised contrastive learning for non-intrusive speech quality assessment. In *Proc. Interspeech*, pp. 2623–2627, 2022.

[51] S. Tao, W. Zhang, H. Li, and W. Rao. Perceptually-motivated speaker embedding learning using subjective ratings. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, Vol. 29, pp. 2785–2797, 2021.

[52] Y. Zhang, M. Chen, D. Huang, D. Wu, and Y. Li. Learning a deep embedding for user-item co-representation in music recommendation. In *Proc. ICASSP*, pp. 2269–2273, 2017.

[53] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov. Large-scale contrastive language-audio pretraining with feature fusion and keyword-to-caption augmentation. *arXiv preprint arXiv:2211.06687*, 2022.

[54] S. Manco, B. McFee, J. H. Lee, D. P. W. Ellis, A. Jansen, and Q. Huang. Muq: Self-supervised music representation learning with melody and rhythm quizzes. In *Proc. ISMIR*, pp. 551–559, 2023.

[55] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville. Film: Visual reasoning with a general conditioning layer. In *Proc. AAAI*, pp. 3942–3951, 2018.

[56] X. Liu, H. Kong, X. Zhao, E. Plumbley, W. Wang, J. Du, H. Li, M. D. Plumbley, V. Kilic, and D. Wang. Separate what you describe: Language-queried audio source separation. In *Proc. Interspeech*, pp. 3745–3749, 2024.

[57] H. Liu, Q. Kong, X. Tian, Y. Zhao, D. Wang, C. Huang, and Y. Wang. Clapsep: Leveraging contrastive pre-trained models for multi-modal query-conditioned target sound extraction. In *Proc. ICASSP*, pp. 1266–1270, 2024.

[58] J. Gao, X. Chang, T. Yu, and S. Watanabe. Task-aware unified source separation. In *Proc. ICASSP*, pp. 12651–12655, 2024.

[59] A. Riou, S. Lattner, G. Hadjeres, M. Anslow, and G. Peeters. Stem-jepa: A joint-embedding predictive architecture for musical stem compatibility estimation. In *Proc. ISMIR*, pp. 625–633, 2024.

[60] A. Riou, A. Gagneré, G. Hadjeres, S. Lattner, and G. Peeters. Zero-shot musical stem retrieval with joint-embedding predictive architectures. In *Proc. ICASSP*, 2025. 5 pages.

[61] W. Zhang, W. Lei, X. Xu, and X. Xing. Improved music genre classification with convolutional neural networks. In *Proc. Interspeech*, pp. 3304–3308, 2016.

[62] J. Foote, M. Cooper, and U. Nam. Audio retrieval by rhythmic similarity. In *Proc. ISMIR*, pp. 265–266, 2002.

[63] J. Paulus and A. Klapuri. Measuring the similarity of rhythmic patterns. In *Proc. ISMIR*, pp. 150–156, 2002.

[64] E. Pampalk. *Computational models of music similarity and their application in music information retrieval*. PhD thesis, Vienna University of Technology, 2006.

[65] T. Pohle, D. Schnitzer, M. Schedl, P. Knees, and G. Widmer. On rhythm and general music similarity. In *Proc. ISMIR*, pp. 525–530, 2006.

[66] E. Pampalk, A. Flexer, and G. Widmer. Improvements of audio-based music similarity and genre classification. In *Proc. ISMIR*, pp. 628–633, 2005.

[67] A. Honingh, M. Panteli, T. Brockmeier, D. I. L. Mejía, and M. Sadakata. Perception of timbre and rhythm similarity in electronic dance music. *New Music Research*, pp. 373–390, 2015.

[68] S. McAdams, S. Vieillard, O. Houix, and R. Reynolds. Perception of musical similarity among contemporary thematic materials in two instrumentations. *Music Perception*, pp. 207–237, 2004.

[69] E. Manilow, G. Wichern, P. Seetharaman, and J. L. Roux. Cutting music source separation some slakh: A dataset to study the impact of training data quality and quantity. In *Proc. WASPAA*, pp. 45–49, 2019.

[70] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. In *Proc. ICLR*, 2014. 13 pages.

[71] C. J. Clopper and E. S. Pearson. The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika*, pp. 404–413, 1934.

[72] L. van der Maaten and G. Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, pp. 2579–2605, 2008.

研究業績

論文誌

[1] T. Imamura, Y. Hashizume, W.-C. Huang, and T. Toda, "Music Similarity Representation Learning Focusing on Individual Instruments with Source Separation and Human Preference," *APSIPA Transactions on Signal and Information Processing*, Vol. 14, No. 4, e305, pp. 1–29, 2025.

国際会議

[2] T. Imamura, Y. Hashizume, and T. Toda, "Multi-Task Learning Approaches for Music Similarity Representation Learning Based on Individual Instrument Sounds," *Proc. APSIPA ASC*, 6 pages, 2024.

[3] T. Imamura, T. Komatsu, H. Munakata, and T. Toda, "Audio-Visual Feature Fusion for Calibrating Relevance Scores of Video Moment Retrieval," *Proc. IEEE International Conference on Acoustics, Speech, and Signal Processing*, 5 pages, 2026 (Accepted).

[4] H. Munakata, T. Imamura, T. Nishimura, and T. Komatsu, "CASTELLA: Long Audio Dataset with Captions and Temporal Boundaries," *Proc. IEEE International Conference on Acoustics, Speech, and Signal Processing*, 5 pages, 2026 (Accepted).

国内大会・研究会論文

[5] 今村 剛大, 橋爪 優果, 戸田 智基, “個別楽器音に基づく楽曲間類似度表現学習における音源分離の活用法,” 情報処理学会研究報告, Vol. 2024-MUS-140, No. 54, pp. 1–7, 2024.

[6] 今村 剛大, 西村 太一, 小松 達也, 戸田 智基, “動画内区間検索及びハイライト検出における音響特徴量活用の有効性,” 日本音響春季研究発表会講演論文集, 3-P-16, pp. 1125–1128, 2025.

[7] 今村 剛大, 橋爪 優果, ホワン ウェンチン, 戸田 智基, “個別楽器音に基づく知覚的楽曲間類似度表現学習,” 情報処理学会研究報告, Vol. 2025-MUS-142, No. 7, pp. 1–9, 2025.

[8] 今村 剛大, “個別楽器音に基づく知覚的楽曲間類似度表現学習,” 第 29 回東海地区音声関連研究室修士論文中間発表会, 2025.

[9] 今村 剛大, 小松 達也, 宗像 北斗, 戸田 智基, “動画内区間検索における関連度値校正のための音響・映像特徴量統合,” 日本音響学会研究発表会講演論文集, 1-5-14, 4 pages, 2026.

[10] 宗像 北斗, 今村 剛大, 西村 太一, 小松 達也, “音響区間検索のためのデータセット構築,” 日本音響学会研究発表会講演論文集, 2-1-10, 4 pages, 2026.

[11] 今村 剛大, 橋爪 優果, ホワン ウェンチン, 戸田 智基, “個別楽器音に着目した楽曲間類似度表現学習におけるテキスト表現による楽器指定,” 電子情報通信学会技術研究報告, 7 pages, 2026.

受賞

[12] Selected as the Best Student Paper Candidate for APSIPA ASC 2024

[13] 令和 7 年度名古屋大学情報学研究科知能システム学専攻 学生が選ぶ最優秀発表賞

[14] 第 29 回東海地区音声関連研究室修士論文中間発表会 ポスター賞, 総合第 5 位